Trabalho de Conclusão de Curso de Engenharia da Computação

RADARTORRES:
PROTÓTIPO PARA DETECÇÃO, LOCALIZAÇÃO E SELEÇÃO AUTOMÁTICA DE TORRE COM CONTROLADOR HEURÍSTICO-NEUROEVOLUTIVO

RadarTorres:
a prototype for target detection, localization and automatic tower selection with a heuristic-neuroevolutionary controller

Gabriel Vasconcellos de Morais[1]
Matheus Emanoel Gomes Souza[2]
Anker Douglas Loss[3]

RESUMO

A construção de protótipos de sensoriamento com hardware acessível é um recurso didático relevante em Engenharia da Computação, por permitir explorar de forma prática conceitos de aquisição de dados, rastreamento e tomada de decisão automática. Este trabalho apresenta o RadarTorres, um protótipo que detecta um alvo em movimento, estima sua posição e decide, entre um conjunto de torres candidatas posicionadas ao redor de uma base central, qual delas deve responder a esse alvo – problema central que o trabalho busca resolver: como identificar, localizar e atribuir automaticamente a torre mais adequada a cada alvo, de forma auditável e sem depender de sensores ou atuadores de uso industrial. O sistema combina dois sensores ultrassônicos (que medem a distância pelo eco do ultrassom) com quatro câmeras de 720p, processa quadros de vídeo (*frames*) e classifica o alvo por sua cor, formato e tamanho. O protótipo converte as leituras de ângulo e distância em posição cartesiana, exibindo-as em tempo real em um radar circular, seleciona automaticamente a torre mais adequada para cada alvo e registra em auditoria toda ação executada. Essa seleção combina uma heurística determinística, escrita como regras explícitas de engenharia, com uma rede neural que aprende, por meio de um algoritmo genético próprio, a refinar essa escolha e o instante do acionamento. O treinamento dessa rede ocorre inteiramente antes da operação do sistema, em um ambiente simulado que executa gerações de episódios de teste até evoluir os parâmetros da rede; concluído o treinamento, esses parâmetros são incorporados de forma fixa à aplicação, de modo que, durante a execução real, o sistema apenas aplica o que foi aprendido previamente, sem ajustar seus parâmetros em tempo real. O processamento e a tomada de decisão são concentrados em uma aplicação desktop, com arquitetura pensada para permitir evolução

[1]Graduando(a) em Engenharia da Computação pela Faculdade do Centro Leste – UCL. E-*mail*: gabrielmorais@ucl.br
[2]Graduando(a) em Engenharia da Computação pela Faculdade do Centro Leste – UCL. E-*mail*: matheusemanoel@ucl.br
[3]Orientador(a). Mestre em xxx pela xxx. E-*mail*: anker@ucl.br

futura sem exigir hardware adicional. Discutem-se, por fim, as limitações inerentes à abordagem de hardware acessível e de baixo custo adotada, e o fato de a validação do protótipo, até o momento, ter sido realizada inteiramente por simulação de software, já que a estrutura física ainda não foi montada nem testada.

Palavras-chave: Detecção e rastreamento de alvos; Seleção automática de torre; Controlador heurístico-neuroevolutivo; Arduino; Protótipo.

ABSTRACT

This work presents RadarTorres, a prototype developed as a Final Course Project in Computer Engineering that detects a moving target, estimates its position, and decides, among a set of candidate towers placed around a central base, which one should respond to that target – the central problem this work addresses: how to automatically identify, localize, and assign the most suitable tower to each target, in an auditable way and without relying on industrial-grade sensors or actuators. The system combines two ultrasonic sensors (which measure distance by ultrasound echo) with four 720p cameras, processes video frames, and classifies the target by color, shape, and size. The prototype converts angle and distance readings into Cartesian position, displaying them in real time on a circular radar, automatically selects the most suitable tower for each target, and logs every executed action for auditing. This selection combines a deterministic heuristic, written as explicit engineering rules, with a neural network that learns, through a custom genetic algorithm, to refine that choice and the activation timing. Training of this network happens entirely before the system is put into operation, in a simulated environment that runs generations of test episodes until the network's parameters evolve; once training is complete, these parameters are embedded as fixed values into the application, so that, during actual execution, the system only applies what was previously learned, without adjusting its parameters in real time. Processing and decision-making are concentrated in a desktop application, with an architecture designed to allow future evolution without requiring additional hardware. Finally, the limitations inherent to the accessible, low-cost hardware approach adopted are discussed, as is the fact that validation of the prototype has so far been carried out entirely through software simulation, since the physical structure has not yet been assembled or tested.

Keywords: Target detection and tracking; Automatic tower selection; Heuristic-neuroevolutionary controller; Arduino; Prototype.

1 Introdução

Sistemas automáticos de detecção e resposta a alvos exigem, além de identificar um estímulo, rastrear com precisão sua posição e aplicar regras de decisão que evitem respostas indevidas – tarefas comumente resolvidas com sensores de radar, de custo elevado. Como alternativa a esse tipo de equipamento, este trabalho adota técnicas de visão computacional, aliadas a hardware acessível, como parte central da arquitetura do protótipo. Protótipos didáticos construídos dessa forma desempenham papel importante nesse processo, por permitirem que esses conceitos sejam explorados de forma prática e replicável em laboratório, reproduzindo os princípios de sensoriamento, rastreamento e decisão presentes em sistemas mais sofisticados.

O protótipo resultante, denominado RadarTorres, combina sensores ultrassônicos e câmeras para detectar um alvo, estimar sua posição em um radar circular e decidir, entre um conjunto de torres candidatas dispostas ao redor de uma base central, qual delas deve responder a esse alvo. Essa decisão não é tomada apenas por regras fixas: uma rede neural, evoluída por um algoritmo genético próprio, aprende a refinar a escolha da torre e o instante do acionamento, sempre dentro dos limites que uma camada de regras explícitas (a heurística) já considera seguros. Esse aprendizado acontece em duas etapas bem separadas: antes da operação do sistema, em um ambiente de treinamento simulado, onde a rede evolui ao longo de muitas gerações de episódios de teste; e, depois de treinada, apenas na forma de inferência durante a execução real, sem qualquer ajuste adicional de seus parâmetros em tempo de operação. O problema central que este trabalho busca resolver é, portanto, como automatizar essa cadeia – detectar, localizar e selecionar a torre mais adequada a cada alvo – de forma auditável e replicável em laboratório, sem depender de sensores ou atuadores de uso industrial.

2 Desenvolvimento

2.1 Revisão da literatura e fundamentação teórica

Sistemas de detecção e rastreamento de alvos costumam recorrer a sensores como radar, de custo elevado. Como alternativa, sensores acessíveis podem ser combinados de modo que as limitações de um sejam compensadas pelas qualidades do outro. Sensores ultrassônicos, como o HC-SR04, medem distância com boa confiabilidade em curto alcance, mas não distinguem o tipo do obstáculo; câmeras, por sua vez, fornecem informação semântica, porém dependem das condições de iluminação e exigem maior poder de processamento (MAJONI et al., 2025). A fusão de sensores (*sensor fusion*) combina as duas modalidades para aproveitar essa complementaridade.

Majoni et al. (2025) descrevem uma arquitetura em que um Arduino Mega trata o sensoriamento ultrassônico de baixa latência, enquanto um Raspberry Pi processa as imagens da câmera com uma rede YOLOv4-tiny, com comunicação serial entre os dois. Essa divisão de papéis é análoga à do RadarTorres, em que o Arduino realiza a aquisição e a aplicação desktop concentra o processamento.

A literatura também mostra que sensores ultrassônicos acessíveis podem complementar outras fontes de sensoriamento em sistemas de rastreamento, com a precisão melhorada por predição baseada em filtro de Kalman e fusão com a distância medida pelos ultrassônicos (BAEK et al., 2020). O mesmo trabalho observa que as leituras ultrassônicas se tornam ruidosas em distâncias maiores, o que motiva o uso de filtragem.

Definidos o alvo e sua posição, resta decidir qual recurso deve responder. Na literatura de defesa, esse problema é tratado como avaliação de ameaças e atribuição de armas (*Threat Evaluation and Weapon Assignment*, TEWA), no qual as informações dos sensores alimentam as etapas de detecção, rastreamento e identificação, seguidas da avaliação da ameaça e da atribuição dos recursos. As abordagens desse tipo de problema costumam ser classificadas em ameaça por ameaça, em que os recursos são atribuídos sequencialmente, e multiameaça, em que o conjunto de ameaças é considerado simultaneamente.

O RadarTorres adota uma abordagem simples, por proximidade, aplicada alvo a alvo, com propósito exclusivamente demonstrativo (laser de baixa potência, LED ou simulação, sem armamento real); a abordagem multiameaça fica como trabalho futuro.

O refinamento dessa escolha por proximidade – e o instante de disparo – é feito por uma pequena rede neural *feedforward* (6 entradas, 1 camada oculta de 8 neurônios, 2 saídas, ativação tanh), cujos pesos não são ajustados por retropropagação, mas evoluídos por um algoritmo genético próprio (seleção por torneio, *crossover* uniforme, mutação gaussiana, elitismo), auditável e sem dependência de biblioteca de aprendizado de máquina. Such et al. (2017) mostram que algoritmos genéticos são uma alternativa competitiva ao treino por gradiente em tarefas de aprendizado por reforço, em redes de porte bem maior do que a aqui empregada (até quatro milhões de parâmetros, contra os 74 parâmetros da rede do RadarTorres). Esse resultado sustenta a escolha do algoritmo genético como método de treinamento, mas não implica, por si só, que aumentar o número de camadas ou neurônios seja desnecessário; por isso, a estratégia adotada para ampliar o desempenho do controlador prioriza o ajuste dos hiperparâmetros da busca evolutiva (tamanho de população, paralelização da avaliação de fitness, enriquecimento do sinal de recompensa), sem descartar, a priori, uma rede maior caso evidências futuras mostrem que a capacidade atual seja o fator limitante.

A arquitetura híbrida do controlador – heurística que restringe o espaço de ações antes da rede decidir, e volta a intervir depois, vetando o disparo – tem paralelo direto com duas técnicas da literatura de aprendizado por reforço. A primeira é o mascaramento de ações inválidas (*action masking*): Huang e Ontañón (2020) mostram, para algoritmos de gradiente de política, que mascarar o espaço de ações antes da amostragem corresponde a uma atualização de gradiente válida e se torna mais importante quanto maior a fração de ações inválidas – o que justifica tecnicamente a etapa em que a camada heurística do RadarTorres restringe as torres candidatas (nunca ocupada, nunca fora de alcance) antes de a rede neural escolher entre elas. A segunda é o *shielding*: Alshiekh et al. (2017) propõem um componente reativo (*shield*) que intercepta a ação escolhida pela política aprendida e a substitui quando ela violaria uma propriedade de segurança expressa em lógica temporal – papel equivalente ao do veto heurístico final do RadarTorres sobre o disparo, que nunca é delegado à rede. A atribuição de recursos defensivos a ameaças, por sua vez, é tratada na literatura de TEWA tanto no caso ameaça por ameaça quanto no caso multiameaça (NAEEM et al., 2009b, 2009a); o RadarTorres adota deliberadamente a abordagem mais simples (proximidade, alvo a alvo), com a multiameaça permanecendo

como trabalho futuro já apontado anteriormente.

O impacto do treinamento virtual sobre a execução física do controlador é atenuado por uma decisão de projeto central: o mesmo controlador híbrido – heurística e rede neural combinadas – que decide no episódio simulado é o que decide em produção, consultado pelo algoritmo responsável por selecionar a torre a partir das leituras do Arduino real – não há conversão para um formato intermediário (ONNX, TensorFlow Lite) nem reimplementação em outra linguagem ou plataforma, fontes comuns de divergência entre o comportamento treinado e o executado em sistemas de aprendizado por reforço aplicados a robótica. O genoma evoluído é um vetor plano de pesos e vieses, embutido diretamente na aplicação por uma etapa automática de build, que grava o melhor genoma treinado no executável, de onde é carregado por um componente dedicado em tempo de execução; o que muda do ambiente de treino para a operação real é apenas a origem dos dados de entrada (leitura simulada ou leitura do Arduino), nunca a função de decisão em si. Os parâmetros que definem o episódio simulado – alcance de engajamento e certeza mínima para autorizar disparo – também deixaram de ser constantes fixas no código e passaram a ser lidos das mesmas configurações de alcance de mira e de limiar de certeza usadas pelo sistema real, de modo que recalibrar o alcance da câmera ou o limiar de certeza no painel de Configurações recalibra também o mundo de treino, reduzindo a divergência entre o que foi aprendido e o que será executado. Por fim, a rede neural nunca decide isoladamente: ela apenas pondera a escolha dentro do que a camada heurística determinística já considera válida (nunca uma torre ocupada, nunca fora de alcance), de modo que a arquitetura foi concebida para limitar o pior caso de uma generalização imperfeita do treino virtual para a física – no limite, o controlador regrediria ao comportamento puramente heurístico, nunca a uma decisão arbitrária; trata-se, porém, de uma propriedade de projeto ainda não submetida a validação em hardware físico real.

2.2 Procedimentos metodológicos

O percurso metodológico deste trabalho não seguiu o fluxo tradicional de especificação prévia seguida de implementação: o protótipo RadarTorres já existia, em desenvolvimento incremental, antes do levantamento formal de requisitos. Optou-se, portanto, por catalogar os requisitos funcionais e não funcionais diretamente a partir do que já estava implementado no código-fonte da aplicação desktop e da documentação técnica já produzida ao longo do projeto, em vez de defini-los a priori em um documento de especificação anterior à codificação. O treinamento do controlador por neuroevolução, descrito na Seção 2.1, segue essa mesma lógica incremental: a arquitetura híbrida heurística+rede neural foi definida e ajustada em paralelo ao restante do sistema, não a partir de um plano de treinamento fechado desde o início.

Esse levantamento resultou em 25 requisitos funcionais (RF01–RF25) e 20 requisitos não funcionais (RNF01–RNF20), classificados segundo dois critérios objetivos: a **prioridade**, atribuída conforme a criticidade de cada requisito para a operação central do sistema (comunicação serial, rastreamento, seleção de torre, modos de operação e segurança recebem prioridade Alta; suporte administrativo e ferramental, Média; conveniências de interface, Baixa); e o **status**, que reflete o estado real de implementação constatado no código no momento do levantamento – Implementado, Parcial ou Planejado –, e não a intenção original de projeto. Cada requisito foi, além disso, rastreado até a classe ou

método do código-fonte que o realiza, registro mantido em uma matriz de rastreabilidade dedicada, de modo que qualquer afirmação sobre o grau de implementação do protótipo possa ser verificada diretamente no código. Divergências encontradas entre o comportamento observado no código e a nomenclatura ou fluxo originalmente esperado também foram registradas explicitamente, em vez de omitidas ou corrigidas silenciosamente na documentação.

A parte física do RadarTorres (torres, motores, sensores montados em campo) ainda não foi implementada nem validada. Toda a validação funcional relatada neste trabalho foi realizada por simulação de software: a lógica de rastreamento de alvos e de seleção automática de torre foi exercitada de ponta a ponta sem depender de uma porta serial conectada a hardware real, o que impõe um limite claro ao escopo dos resultados relatados – eles atestam a corretude da lógica de decisão implementada em software, mas não substituem uma validação de campo com sensores e torres físicas, deixada como trabalho futuro.

A mesma ressalva se aplica, com reforço adicional, ao controlador treinado por neuroevolução: o mundo simulado em que os genomas são avaliados é uma aproximação idealizada do ambiente físico – os alvos nascem na borda de um círculo e avançam de forma quase radial, sem o ruído típico de leituras ultrassônicas reais; a certeza de identificação do alvo pela câmera é modelada como uma função sintética que cresce com o tempo de observação, e a probabilidade de errar o disparo é uma função assumida, crescente com a velocidade do alvo – nenhuma delas calibrada com dados de campo, já que o hardware ainda não foi montado. Essa distância entre simulação e realidade física não é apenas teórica: durante este trabalho, identificou-se e corrigiu-se uma falha em que a certeza de identificação do alvo era sorteada uma única vez, no nascimento, e nunca era atualizada – cerca de 70% dos alvos simulados nasciam permanentemente abaixo do limiar mínimo de disparo e jamais podiam ser abatidos, independentemente da qualidade do genoma, mascarando qualquer evolução real do controlador sob a aparência de estagnação. O episódio é citado aqui como evidência concreta de que uma premissa equivocada na simulação pode invalidar silenciosamente o processo de treinamento sem que isso seja percebido pelas métricas agregadas, reforçando a necessidade de validação cruzada entre o comportamento do genoma treinado e o comportamento observado em campo, com hardware físico, antes de se confiar no controlador em um cenário de operação real – validação que permanece como trabalho futuro, nos mesmos termos já apontados para o restante do protótipo.

A Tabela 1 quantifica o achado, a partir do histórico de treinamento persistido localmente (`historico_treinamento_geracoes` e `marcos_fitness_treinamento`, tabelas descritas na Seção 2.5). Antes da correção (commit `a02d46a`), o fitness médio da população permaneceu estagnado em torno de 9 ao longo de 51 blocos de 500 gerações (25.500 gerações treinadas, entre 13h40 e 14h57 do mesmo dia), mesmo com o melhor indivíduo de cada bloco oscilando entre 98 e 145 – sinal de que indivíduos pontualmente sortudos conseguiam boa pontuação, sem que a população como um todo convergisse, exatamente o efeito esperado de 70% dos alvos nascerem abaixo do limiar de disparo. Depois da correção, a taxa de cobertura (fração de alvos que chegam a ser disparáveis) sobe para 100% em todas as cinco amostras de comportamento do melhor indivíduo registradas na mesma tarde, e o fitness médio da população em uma amostra recente de 300 gerações (27/10, gerações 1141–1440) sobe para 134,17, muito mais próximo do fitness do melhor indivíduo (137,35)

do que o patamar de 9 observado antes da correção. O genoma embutido no executável (`genoma-controlador.json`) corresponde à geração 5377, com `MelhorFitness` = 136,98.

Table 1: Fitness da população antes e depois da correção do bug de certeza estática (commit `a02d46a`), a partir do histórico de treinamento persistido localmente.

Métrica	**Antes (bug)**	**Depois (corrigido)**
Fitness médio da população	≈ 9,11 (min. 8,37, máx. 9,43; 51 blocos de 500 gerações)	134,17 (min. 121,31, máx. 150,60; amostra de 300 gerações)
Melhor fitness por bloco/geração	97,75 a 144,95 (média 119,62)	137,35 em média (122,81 a 155,47)
Taxa de cobertura dos alvos	não medida diretamente – ≈ 70% dos alvos permanentemente abaixo do limiar	100% (5/5 amostras pós-correção)
Genoma embutido no executável	–	geração 5377, fitness 136,98

2.2.1 Ambiente computacional

Os experimentos controlados de hiperparâmetros relatados na Seção 2.3.6 e os tempos de treinamento ali citados (entre 14 e 75 segundos, para 300 gerações) foram executados em uma única máquina, cuja configuração de hardware e software é descrita na Tabela 2. O registro explícito desse ambiente é condição necessária para que os tempos medidos sejam interpretáveis: o laço de avaliação do algoritmo genético roda inteiramente sobre a CPU, sem qualquer aceleração por GPU – a placa de vídeo integrada da máquina de testes não possui suporte a CUDA nem é utilizada pelo `AlgoritmoGenetico` ou pelo `AmbienteTreinamento`, de modo que o tempo de treinamento depende do desempenho do processador e não da placa gráfica. Reportar hardware, sistema operacional e *runtime* é, portanto, pré-condição para que os tempos absolutos apresentados nas Figuras 5 e 6 sejam reproduzíveis ou comparáveis em outra máquina: um processador mais rápido, mais núcleos ou memória disponível alteram os segundos medidos sem alterar a lógica avaliada, e a ausência de uso de GPU explica por que o tempo escala com o tamanho da população (mais indivíduos avaliados por geração) e quase não escala com o tamanho da rede neural (Seção 2.3.6, parágrafo de custo computacional) – o gargalo é o número de episódios simulados em CPU, não a propagação da rede, pequena demais para pesar no tempo total.

Essa descrição de ambiente cobre especificamente os onze experimentos de hiperparâmetros da Seção 2.3.6, executados nesta máquina e nesta configuração de *software* no mesmo dia. Ela **não** se estende ao treinamento mais longo que produziu o genoma de produção embutido no executável (`Resources/ControladorTreinado/genoma-controlador.json`): o histórico de treinamento persistido localmente (Tabela 1 e Seção 2.5) registra gerações, fitness e horários, mas não qual máquina executou cada sessão de treinamento, de modo que não é possível afirmar que o genoma de produção foi gerado neste mesmo ambiente de

Table 2: Ambiente computacional dos experimentos de hiperparâmetros (Seção 2.3.6).

Componente	**Especificação**
Processador	Intel® Core™ i5-4200U @ 1,60 GHz, 2 núcleos físicos / 4 threads, clock máximo de 2,30 GHz
Memória RAM	16 GB
Placa de vídeo	Intel HD Graphics Family (integrada), 1024 MB de memória compartilhada, sem GPU dedicada e sem aceleração CUDA
Sistema operacional	Microsoft Windows 11 Home, versão 10.0.22631 (*build* 22631), 64 bits
Runtime	.NET SDK 9.0.320, *runtime* Microsoft.WindowsDesktop.App 9.0.x, *target framework* `net9.0-windows`
Principais dependências	Microsoft.Data.Sqlite 9.0.0, Microsoft.Extensions.* 9.0.0, Microsoft.ML.OnnxRuntime 1.20.1, AForge.Video / AForge.Video.DirectShow 2.2.5, System.Drawing.Common 9.0.0, PDFsharp 6.2.4, System.IO.Ports 9.0.0

hardware. Essa lacuna de rastreamento é registrada aqui como limitação explícita e como trabalho futuro: o `AmbienteTreinamento` poderia passar a persistir, junto do histórico de gerações, uma identificação da máquina de execução (processador, núcleos e presença ou não de GPU), tornando toda sessão de treinamento – e não apenas os experimentos controlados desta seção – igualmente rastreável e reproduzível.

2.3 Projeto e implementação

2.3.1 Módulo de detecção de alvos

O módulo de detecção utiliza dois sensores ultrassônicos HC-SR04 instalados de costas um para o outro no topo de um mastro, na torre central. O mastro é movido por um motor de passo 28BYJ-48 que oscila 180°, de modo que, em conjunto, os dois sensores cobrem uma varredura de 360°. Cada sensor emite pulsos de 40 kHz e calcula a distância pelo atraso do eco, segundo a relação $d = \frac{v \cdot \Delta t}{2}$, em que v é a velocidade do som no ar (cerca de 343 m/s à temperatura ambiente). A cada leitura, o Arduino envia à aplicação desktop, pela porta serial, o ângulo e a distância em protocolo de texto simples, que a aplicação converte em posição cartesiana e exibe no radar circular de quatro quadrantes.

O protocolo é textual em ASCII, transportado pela porta serial USB a 9600 bauds por padrão, com cada mensagem terminada por `\n` e composta por um tipo em maiúsculas seguido de pares chave-valor separados por ponto e vírgula. Uma leitura de alvo chega na forma `TARGET;ID=1;ANGLE=45;DIST=2.80`, em que `ANGLE` é dado em graus no intervalo $[0, 360)$ e `DIST` em metros. O ângulo segue a convenção de bússola – 0° apontando para o Norte, sentido horário –, escolhida por ser a leitura mais intuitiva para quem opera um radar, e a conversão para coordenadas cartesianas de mundo, feita por uma rotina

dedicada de conversão de coordenadas polares para cartesianas, é dada por $x = d \cdot \sin\theta$ e $y = d \cdot \cos\theta$, com θ em radianos. A partir do par (x, y), o quadrante do alvo é determinado pelos sinais das duas coordenadas (por um algoritmo auxiliar de identificação de quadrante) e a distância até cada torre candidata pela distância euclidiana clássica (calculada por uma rotina dedicada de cálculo de distância). Leituras com campos ausentes, não numéricos, com ângulo fora do intervalo válido ou com distância negativa são convertidas em mensagens de erro registradas no console de eventos, nunca em exceções – falhas de sensor ou de cabo produzem degradação graciosa, e não interrupção da aplicação.

2.3.2 Projeto elétrico e estrutural

O projeto elétrico é baseado em um Arduino Uno, plataforma disponível no simulador Tinkercad usado para simular o circuito. Os sinais dos motores de passo são gerados por registradores de deslocamento 74HC595 em cascata, e os motores 28BYJ-48 são acionados por drivers ULN2003, alimentados por uma fonte de 5 V/15 A. Cada uma das quatro torres armadas possui dois motores 28BYJ-48 (movimentos de pan e tilt), um laser de baixa potência e um LED de cor própria; o acionamento é exclusivamente demonstrativo. Na torre central, o mastro dos sensores não é acoplado diretamente ao eixo do motor: ele assenta em um disco que gira sobre um rolamento axial 51108, acionado pelo motor por um cubo duplo-D. A passagem dos fios fica próxima ao eixo central, com folga de cabo em vez de anel coletor (*slip ring*), já que o giro é limitado a 180°. A torre central é cerca de 5 cm mais alta que as torres armadas (cerca de 137,5 mm de altura). As peças estruturais são impressas em 3D, em formato de torre, com suporte para rolamento axial na base – o que permite a rotação da estrutura –, comum às cinco torres. As torres armadas têm, além disso, suportes próprios para os motores e para as câmeras, que cumprem o papel dos "canhões" de acionamento demonstrativo; a torre central tem suporte próprio para os sensores ultrassônicos no topo do mastro. Todas essas peças, assim como o restante do projeto, existem até o momento apenas em projeto digital (modelagem 3D e simulação elétrica), sem montagem física realizada.

2.3.3 Módulo de visão

O módulo de visão utiliza quatro câmeras de 720p conectadas por USB ao computador, associadas aos quadrantes do radar, e processa os quadros de vídeo (*frames*) para classificar o alvo por sua cor, formato e tamanho. Cada quadro capturado é entregue já decodificado à detecção, que executa localmente um modelo YOLO26, na variante nano, em formato ONNX, para propor as regiões candidatas da imagem. Cada candidata é então comparada ao perfil do alvo previamente cadastrado – definido por cor, formato e tamanho, e opcionalmente por fotos de referência recortadas no objeto de interesse. Havendo foto de referência, a comparação combina um histograma de matiz e saturação com uma grade espacial de cor média, usados como assinatura do objeto; na ausência de foto, o critério recai sobre a fração de pixels com a cor cadastrada e sobre a classificação de formato. Quando o detector não propõe nenhuma caixa com a cor do perfil, as regiões candidatas passam a ser propostas por segmentação de cor, como último recurso na ordenação de candidatos.

O envio das informações resultantes ao Arduino, para guiar o apontamento da torre

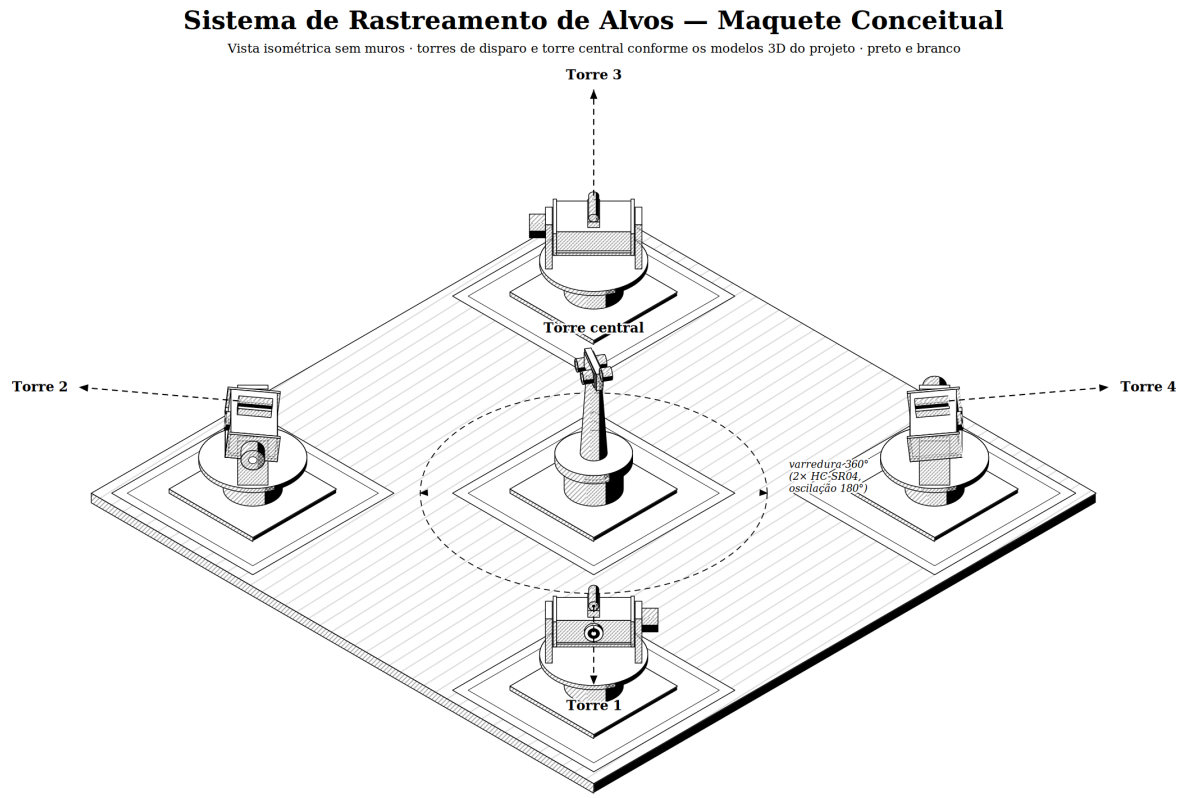


Figure 1: Maquete conceitual do arranjo das cinco torres (vista isométrica): quatro torres de disparo e a torre central com varredura de 360° (dos autores).

(movimentos de pan e tilt), foi projetado mas ainda não está implementado: o protocolo serial atual não possui comando de apontamento, e a fusão entre a posição estimada pela visão e a distância medida pelos sensores ultrassônicos permanece como etapa planejada. Como o hardware ainda não foi montado, a validação funcional descrita neste trabalho foi feita por simulação, e nenhum resultado de campo é relatado.

2.3.4 Fluxo operacional

Em operação, o sistema segue estas etapas: (1) o Arduino varre o ambiente com os dois sensores ultrassônicos e envia ângulo e distância à aplicação; (2) a aplicação converte cada leitura em posição cartesiana, determina o quadrante, exibe o alvo no radar e registra a detecção; (3) em paralelo, as câmeras fornecem quadros de vídeo, e o módulo de visão classifica o alvo por cor, formato e tamanho; (4) a aplicação seleciona, entre as torres armadas disponíveis, a mais adequada para o alvo, priorizando as do mesmo quadrante e, entre elas, a de menor distância euclidiana (por proximidade, alvo a alvo); (5) o comando é enviado ao Arduino, que aciona a torre selecionada; (6) o acionamento demonstrativo (laser de baixa potência ou LED) só ocorre respeitando a distância mínima de segurança e as demais regras de segurança configuráveis do sistema; (7) toda ação executada é registrada em auditoria.

A seleção de torre e o acionamento dependem do modo de operação escolhido pelo operador, em um modelo de três níveis: no primeiro, os alvos são apenas detectados e exibidos;

no segundo, acrescenta-se a seleção automática da torre, sem acionamento; no terceiro, acrescenta-se o acionamento demonstrativo automático. Quando a regra de segurança reprova um acionamento, ele é bloqueado e o motivo é registrado no console de eventos.

2.3.5 Controlador neuroevolutivo: heurística e rede neural combinadas

O passo (4) do fluxo operacional – escolher, entre as torres armadas disponíveis, a mais adequada para cada alvo, e decidir o instante do acionamento – é resolvido no RadarTorres pela combinação de dois mecanismos de natureza distinta: uma **heurística** determinística, escrita como regras explícitas de engenharia, e uma **rede neural** *feedforward*, cujo comportamento é aprendido por um algoritmo evolutivo próprio, sem biblioteca de aprendizado de máquina. Ambos coexistem no mesmo controlador híbrido, e é essa combinação – não cada mecanismo isoladamente – que determina tanto o comportamento em produção quanto o que é efetivamente treinado.

A heurística é um conjunto de regras fixas, escritas e revisáveis por engenharia, cujo resultado para uma mesma entrada é sempre o mesmo. No RadarTorres ela resolve, em cascata, três camadas de prioridade na seleção da torre: primeiro considera apenas as torres livres do próprio quadrante do alvo; na ausência de candidata, estende-se às torres de quadrante adjacente cujo quadrante de origem não tenha outro alvo concorrente; por fim, na ausência de qualquer uma das duas, recorre a qualquer torre livre restante, de modo que nenhum alvo fique sem cobertura. Cada camada carrega um fator numérico (1,0; 0,5; ou 0,0) que soma-se diretamente à pontuação da candidata. A heurística também impõe cinco regras de segurança e refinamento, cada uma ativável individualmente no painel de Configurações: anti-oscilação, que evita trocar de torre por uma diferença de pontuação dentro de uma margem de empate; priorização por urgência, que permite a um alvo muito próximo da base "tomar" a torre de um alvo mais distante; corredor de tiro, que descarta candidatas cuja linha de disparo atravesse uma zona morta ativa; balanceamento de carga, que prefere, entre torres empatadas, a usada com menor frequência na sessão; e predição de trajetória, que projeta a posição futura do alvo para calcular o ângulo de mira com antecedência de poucos décimos de segundo. Por fim, a heurística impõe dois limites absolutos ao disparo, nunca delegados à rede: um tempo mínimo de mira de 0,3 s e um limiar mínimo de certeza de identificação do alvo (`LimiarConfiancaDisparoPercentual`), abaixo do qual o disparo é recusado independentemente de qualquer outra avaliação.

A rede neural, por sua vez, não decide essas regras de segurança nem a cascata de camadas – ela decide apenas a escolha fina *dentro* do espaço já validado pela heurística. É uma rede *feedforward* totalmente conectada, implementada do zero (sem biblioteca de aprendizado de máquina), com arquitetura de 6 entradas, uma camada oculta de 8 neurônios e 2 saídas, com ativação tanh em todas as camadas. As seis entradas – todas normalizadas no intervalo $[0, 1]$ ou equivalente – são a distância normalizada ao alvo, dois indicadores binários de quadrante (mesmo quadrante e quadrante adjacente), o ângulo de mira normalizado, a velocidade normalizada do alvo e o próprio fator da camada heurística vigente, usado como sinal de contexto. As duas saídas são um ajuste de pontuação, somado à pontuação heurística da candidata, e um valor de confiança de disparo, cujo sinal positivo autoriza o acionamento. Os pesos e vieses da rede – 74 parâmetros, no total, para essa arquitetura – não são ajustados por retropropagação, mas evoluídos por um algoritmo genético: cada genoma é um vetor plano desses 74 números, a população evolui por seleção por

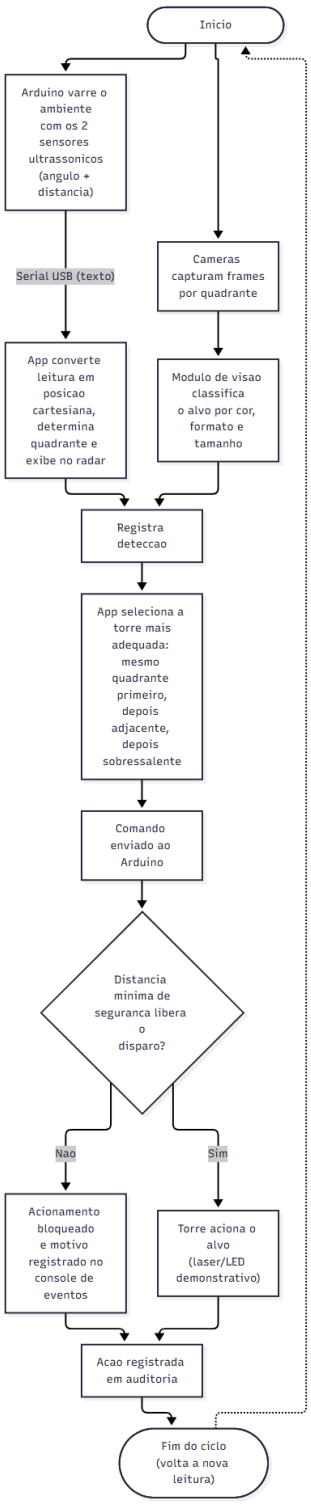


Figure 2: Fluxograma do fluxo operacional do RadarTorres, da leitura dos sensores ao registro em auditoria (dos autores).

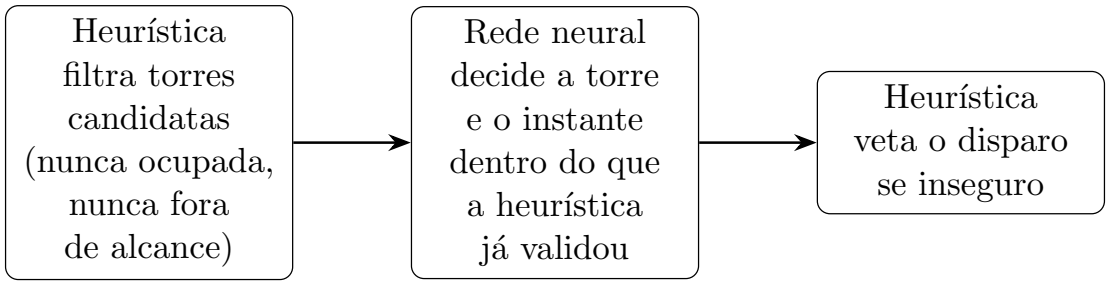
torneio, *crossover* uniforme, mutação gaussiana e elitismo, e o genoma final é embutido na aplicação como um vetor de pesos fixo, sem qualquer etapa de treinamento em tempo de execução.

A combinação entre os dois mecanismos é, portanto, sequencial e hierárquica, nunca uma mistura indiferenciada: a heurística primeiro filtra quais torres são elegíveis e calcula as *features* de entrada (quadrante, ângulo, fator de camada); a rede neural, em seguida, pondera essa pontuação dentro do subconjunto já validado, decidindo qual candidata específica vence o empate fino que a heurística, por si só, não resolveria com a mesma sensibilidade; e, por fim, a heurística volta a atuar como filtro de segurança sobre a decisão de disparo, vetando qualquer autorização da rede que viole o tempo mínimo de mira, a certeza mínima ou uma zona morta ativa. Essa hierarquia tem uma consequência deliberada para o pior caso: uma generalização imperfeita da rede nunca produz uma decisão arbitrária, porque toda saída da rede continua restrita ao espaço de candidatas e ao conjunto de disparos já pré-aprovados pela heurística – no limite, o sistema regride ao comportamento puramente heurístico, nunca a um erro fora de controle.

Esse acoplamento se reflete diretamente no treinamento do controlador. O algoritmo genético não avalia a rede neural isolada: avalia o comportamento do `ControladorHibrido` completo – heurística e rede juntas – em episódios simulados de 45 s, com as torres reais do projeto, alvos nascendo na borda de um mundo circular e avançando em direção à base. O fitness de cada genoma soma recompensas por abate (maiores quanto mais longe da base o alvo é interceptado) e penalidades por alvo que escapa ou cruza um ponto de perda sem decisão, de modo que o genoma é pressionado a aprender a operar bem *dentro* das restrições que a heurística já impõe, e não a contorná-las – não há genoma "vencedor" que dispare fora da zona morta ou abaixo da certeza mínima, porque essas decisões nunca chegam a ser avaliadas como tal pelo ambiente de treino. Essa mesma dependência, no entanto, também é o ponto mais sensível do processo: como o fitness depende inteiramente do comportamento simulado, qualquer premissa equivocada no ambiente de treino se propaga, silenciosamente, para o genoma evoluído. Foi exatamente esse o caso identificado e corrigido neste trabalho – a certeza de identificação do alvo era sorteada uma única vez, no nascimento, e nunca era atualizada, de modo que cerca de 70% dos alvos simulados nasciam permanentemente abaixo do limiar mínimo de disparo e jamais podiam ser abatidos, independentemente da qualidade do genoma, o que mascarava qualquer evolução real sob a aparência de estagnação. A correção – fazer a certeza crescer com o tempo de observação do alvo, como ocorreria com uma câmera real acumulando quadros – e o alinhamento posterior dos parâmetros de alcance de mira e de limiar de certeza usados no treino com os mesmos valores configuráveis em produção (`ConfiguracoesAplicativo.AlcanceMiraMetros`, `LimiarConfiancaDisparoPercentual`) ilustram, em conjunto, por que a fidelidade do ambiente simulado ao comportamento do sistema real é, para um controlador neuroevolutivo, tão determinante para o resultado do treinamento quanto a própria arquitetura da rede ou os hiperparâmetros da busca genética.

2.3.6 Análise experimental de hiperparâmetros

Para justificar tecnicamente a escolha dos hiperparâmetros do algoritmo genético com dados reais de treinamento, em vez de apenas por convenção, foram conduzidos exper-



`ControladorHibrido` – a mesma classe decide no treino simulado e na operação real

Figure 3: Fluxo de decisão do controlador híbrido: a heurística determinística filtra e, ao final, veta; a rede neural decide apenas dentro do espaço já validado (dos autores).

imentos controlados em que se varia *um* hiperparâmetro por vez, mantendo todos os demais fixos. Foram testados três tamanhos de população (30, 60 e 120 indivíduos), três arquiteturas de rede (4, 8 e 16 neurônios na camada oculta, mantendo fixas as 6 entradas e as 2 saídas descritas na Seção 2.3.5) e três taxas de mutação (0,04, 0,08 e 0,16, isto é, a metade, o valor padrão e o dobro da probabilidade de cada gene receber ruído gaussiano na reprodução), totalizando onze execuções independentes.

Cada configuração foi treinada isoladamente por exatamente 300 gerações, com a mesma função de fitness, os mesmos cenários táticos obrigatórios (`CatalogoCenarios.TodosComScript`) e o mesmo ambiente de avaliação do treinamento padrão. Todas as execuções usaram o mesmo `AmbienteTreinamento` e o mesmo `AlgoritmoGenetico` que treinam o controlador em produção, sem nenhum dado simulado ou estimado manualmente. O resultado de cada configuração – população, neurônios ocultos, taxa de mutação, gerações executadas, fitness final, geração em que esse fitness foi alcançado pela primeira vez, curva de convergência, tempo de treinamento e data/hora – foi persistido na tabela `experimentos_hiperparametros` (ver Seção 2.5) e é consultável na tela de Estatísticas de Treinamento, que apresenta cada série comparativa separadamente e destaca a configuração de melhor fitness, a de convergência mais rápida e a de melhor custo-benefício. Os gráficos desta seção são gerados diretamente desses registros.

Efeito sobre a qualidade final do controlador. A Figura 4 apresenta o fitness final das nove combinações de população e arquitetura, com a taxa de mutação fixa em 0,08. O painel (a) agrupa os resultados por arquitetura e o painel (b) pelos mesmos dados organizados por tamanho de população, de modo que cada painel isola visualmente o efeito de um dos dois hiperparâmetros.

O resultado mais relevante da Figura 4 é a *estreiteza* da faixa: as nove configurações terminaram entre 55,59 e 57,27 de fitness, uma variação total de 1,68 ponto, ou cerca de 3% entre o pior e o melhor caso. Não há tendência monotônica em nenhum dos dois painéis – aumentar a camada oculta de 4 para 16 neurônios não melhora consistentemente o resultado (em população 60, por exemplo, o fitness cai de 57,27 para 56,11), e aumentar a população de 30 para 120 indivíduos também não (com 4 neurônios, 60 indivíduos superam 120). O melhor resultado isolado foi o da configuração com população 60 e 4 neurônios ocultos (57,27), mas a margem sobre as demais é pequena demais, diante de uma única execução por configuração, para ser atribuída ao hiperparâmetro em vez da variação

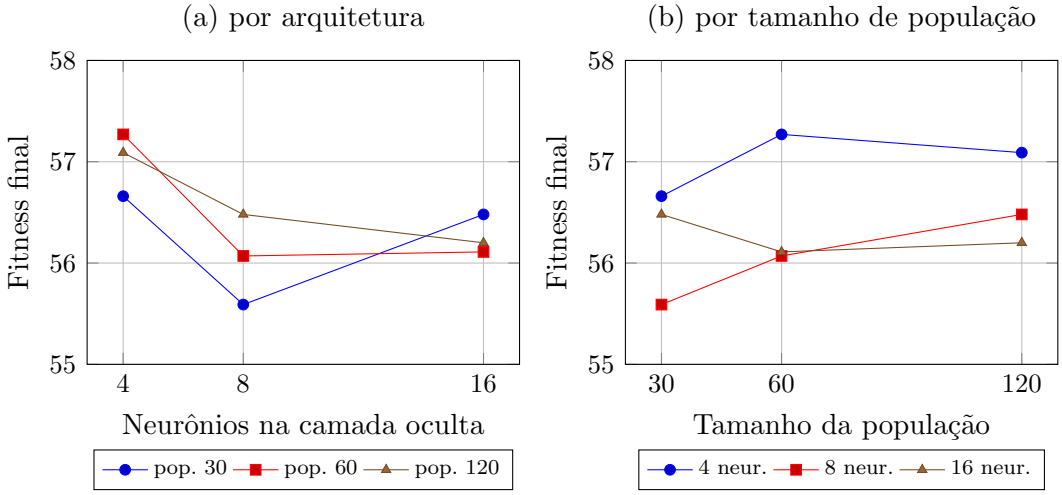


Figure 4: Fitness final (melhor indivíduo ao longo de 300 gerações) das nove combinações de população e neurônios na camada oculta, com taxa de mutação fixa em 0,08. Os dois painéis mostram os mesmos nove pontos, reorganizados para isolar cada hiperparâmetro. Note que o eixo vertical cobre apenas a faixa de 55 a 58, de modo que as diferenças aparentes correspondem a menos de 3% de variação (dos autores).

natural entre trajetórias de um algoritmo estocástico. A leitura defensável, portanto, é que *nenhuma* das configurações testadas produz um controlador mensuravelmente melhor que as outras dentro do horizonte de 300 gerações.

Efeito sobre a velocidade de evolução. Se a qualidade final pouco distingue as configurações, o mesmo não vale para a *velocidade* com que cada uma chega ao seu resultado. A Figura 5 isola o efeito da taxa de mutação sobre a convergência, mantendo fixas a população em 60 indivíduos e a camada oculta em 8 neurônios: o painel (a) traz a curva do melhor fitness acumulado ao longo das gerações e o painel (b), a geração em que cada execução atingiu seu valor final.

A Figura 5 revela o resultado mais nítido de todo o conjunto de experimentos: um *compromisso* entre velocidade e qualidade, na direção prevista pela teoria de algoritmos genéticos. A taxa de mutação mais alta (0,16) foi a que convergiu mais cedo – atingiu seu valor final na geração 116, contra 191 da taxa padrão e 235 da taxa de 0,04, ou seja, em praticamente metade das gerações da configuração mais lenta –, mas foi também a que parou no menor fitness (55,59). Na direção oposta, a taxa de 0,04 foi a mais lenta e a que alcançou o maior fitness (56,35). O painel (a) deixa visível o mecanismo por trás disso: a curva de 0,16 sobe primeiro e achata cedo, enquanto a de 0,04 permanece abaixo das demais até cerca da geração 200 e continua subindo quando as outras duas já estabilizaram. Trata-se do equilíbrio clássico entre exploração e explotação: mais mutação espalha a busca e encontra rapidamente uma região boa, mas atrapalha o refinamento fino em torno dela; menos mutação refina melhor, ao custo de precisar de mais gerações.

Respondendo diretamente à pergunta que motivou este experimento – se alterar a taxa de mutação faz a população evoluir mais rápido –, a resposta observada é sim, e o efeito é considerável no número de gerações (fator de aproximadamente 2 entre 0,04 e 0,16), mas esse ganho **não se traduz em economia de tempo de execução**: as três con-

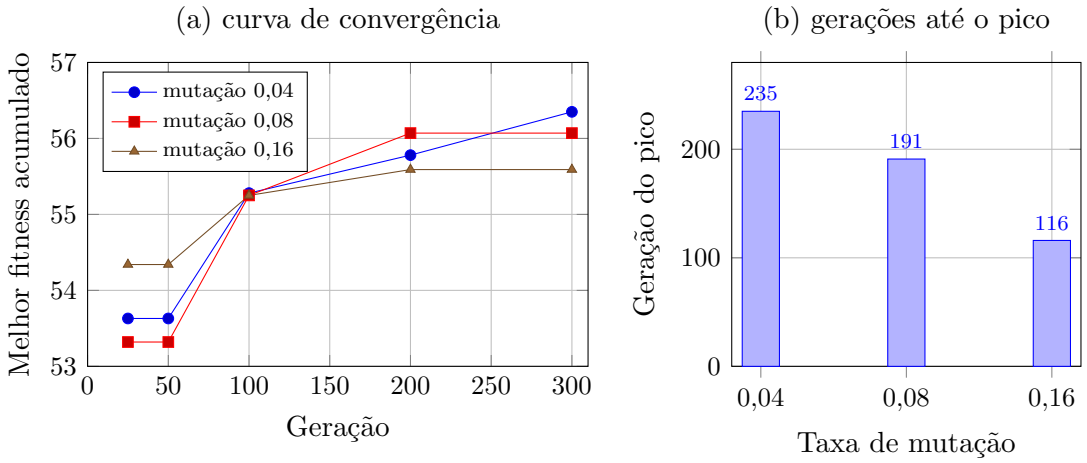


Figure 5: Efeito da taxa de mutação sobre a convergência, com população de 60 indivíduos e 8 neurônios na camada oculta. Em (a), o melhor fitness acumulado nas gerações 25, 50, 100, 200 e 300; em (b), a primeira geração em que cada execução atingiu seu fitness final (dos autores).

figurações levaram, respectivamente, 33,0, 25,8 e 35,4 segundos, porque todas rodaram as 300 gerações completas independentemente de já terem estabilizado. O ganho só se converteria em tempo caso o treinamento adotasse um critério de parada por estagnação, que o RadarTorres não implementa – possibilidade de melhoria registrada aqui como trabalho futuro.

Custo computacional. O tempo de treinamento, por sua vez, respondeu de forma clara e previsível a um único fator: o tamanho da população. A Figura 6 mostra os tempos cronometrados das nove configurações do primeiro experimento.

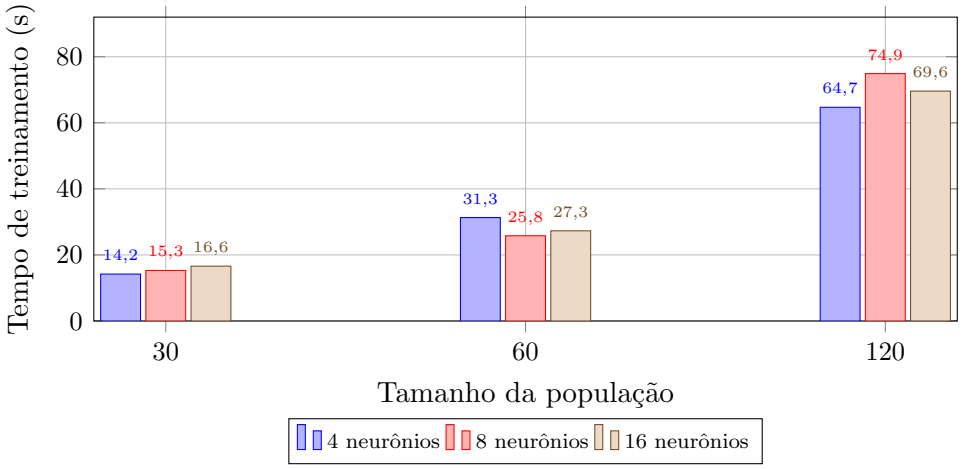


Figure 6: Tempo de parede para treinar 300 gerações em cada uma das nove configurações de população e arquitetura, cronometrado pelo próprio executor de experimentos (dos autores).

O tempo cresce de forma aproximadamente linear com a população e é praticamente insensível à arquitetura: passar de 30 para 120 indivíduos multiplica o tempo por um

fator entre 4,2 e 4,9, enquanto quadruplicar os neurônios da camada oculta (de 4 para 16) altera o tempo em menos de 17% em qualquer das populações. O comportamento é o esperado de um laço que avalia cada indivíduo da população a cada geração: o custo é dominado pela quantidade de episódios simulados, não pelo tamanho da rede avaliada em cada episódio – a rede, com 6 entradas e no máximo 16 neurônios ocultos, é pequena demais para que sua propagação pese diante do custo de simular o ambiente.

Conclusão e escolha dos hiperparâmetros. Combinando os três resultados, a conclusão deste experimento para o RadarTorres é de custo-benefício, não de desempenho. Como nenhuma configuração produziu um controlador mensuravelmente melhor (variação total de 3% no fitness final), e como o custo computacional é governado quase exclusivamente pelo tamanho da população, não há evidência que justifique o gasto adicional de uma população de 120 indivíduos – cerca de 4,5× o tempo de uma população de 30 – nem ganho em adotar uma camada oculta maior. A configuração de produção, população de 60 indivíduos com 8 neurônios ocultos e taxa de mutação 0,08, situa-se no meio das três faixas testadas e é sustentada por estes dados como uma escolha equilibrada: fitness dentro da faixa das demais, tempo de treinamento intermediário e convergência também intermediária entre a mutação que estabiliza cedo demais e a que demora a estabilizar.

Duas ressalvas delimitam o alcance destas conclusões, na mesma linha das já apontadas na Seção 2.2 para o treinamento do controlador em geral. A primeira é amostral: cada configuração corresponde a uma única execução, isto é, a uma única trajetória de evolução, e não à média de repetições independentes com sementes distintas. Diferenças da ordem de um ponto de fitness, como as que separam as nove combinações da Figura 4, são pequenas demais para serem atribuídas com confiança ao hiperparâmetro em si; por isso o texto acima evita eleger uma configuração vencedora em qualidade e se apoia apenas nos efeitos de magnitude maior, como o fator de 2 em gerações até o pico e o fator de 4,5 em tempo de execução. A segunda ressalva é o horizonte: as 300 gerações foram escolhidas para manter cada experimento executável em cerca de um minuto, não necessariamente para captar a convergência completa de cada configuração – o fato de a taxa de mutação 0,04 ainda estar subindo na geração 200 sugere que um horizonte maior poderia, sim, diferenciar melhor as configurações entre si. Uma repetição futura com múltiplas sementes por configuração e um horizonte mais longo é, portanto, trabalho necessário antes de se afirmar superioridade estrita de qualquer combinação, na mesma linha da ressalva geral sobre a fidelidade do ambiente de treino feita na Seção 2.2.

2.4 Diagrama de pacotes

A organização interna da aplicação desktop foi documentada por meio de um diagrama de pacotes, diagrama estrutural da UML que representa a divisão lógica do sistema em pacotes e as dependências existentes entre eles, sem detalhar atributos ou métodos das classes neles contidas. No RadarTorres, cada pacote corresponde a um *namespace* do projeto `RadarTorres.App`, coincidente com uma pasta do código-fonte, e o diagrama foi obtido diretamente do código da *branch* principal do repositório: cada seta representa ao menos uma diretiva `using RadarTorres.App.*` (ou uma referência `clr-namespace` em XAML) presente nos arquivos do pacote de origem, de modo que o diagrama descreve a estrutura efetivamente implementada, e não apenas a pretendida.

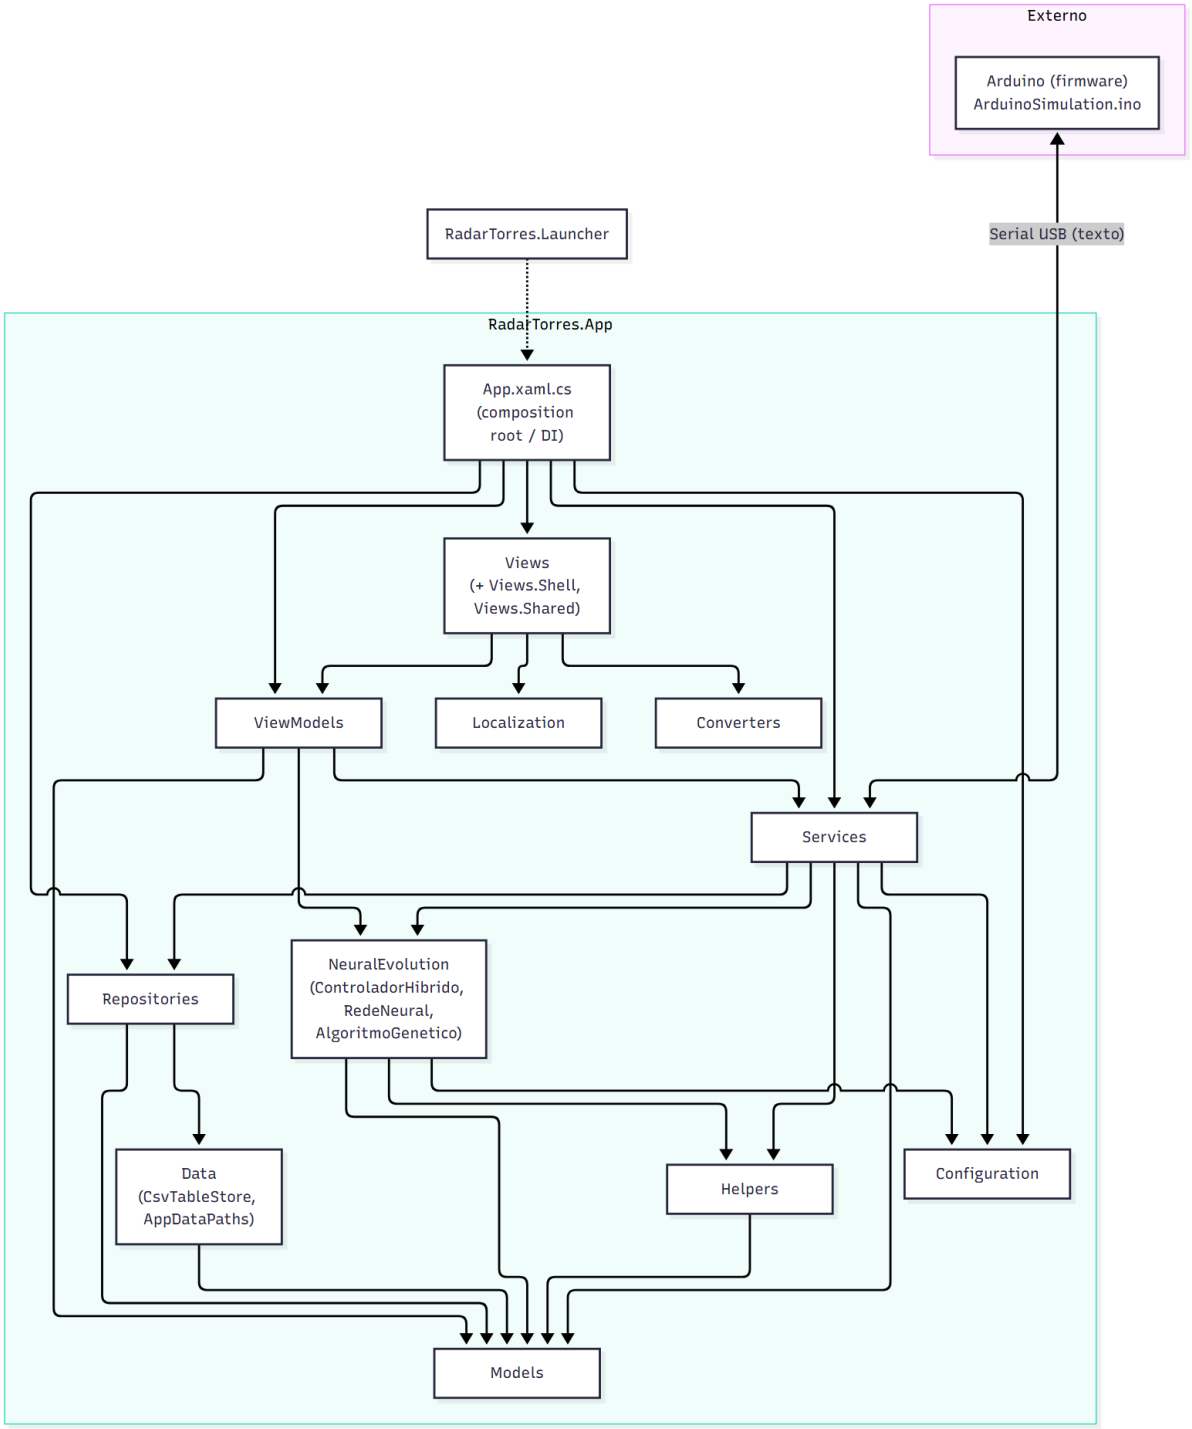


Figure 7: Diagrama de pacotes do RadarTorres. Setas em vermelho indicam dependências que formam ciclos (dos autores).

O fluxo principal de dependências segue a organização do padrão MVVM, de cima para baixo: Views → ViewModels → Services → Repositories → Data → Models. O pacote Models ocupa a posição mais estável do sistema – todos os demais dependem dele e ele não depende de nenhum outro –, o que é desejável para as entidades de domínio, e a separação entre as interfaces de Repositories e a implementação em CSV do pacote Data é o que viabiliza a futura migração para um banco relacional sem alterar ViewModels ou Services. A construção do diagrama a partir do código revelou, também, dependências que formam ciclos entre pacotes: o `NavigationService` importa *namespaces* de Views para instanciar telas (Services → Views, fechando o ciclo com Views → ViewModels → Services), e o `DataSeeder`, responsável pela carga inicial de dados, importa Models, Repositories e Services (Data → Repositories/Services, fechando o ciclo com Repositories/Services → Data). Confirmados em `NavigationService.cs` e `DataSeeder.cs` no código atual, esses dois ciclos continuam presentes, mas a figura acima, regenerada ao nível de pacote e não de classe, não os destaca visualmente – ficam registrados apenas neste parágrafo, em vez de perdidos. Eles não impedem o funcionamento da aplicação, pois todos os pacotes pertencem ao mesmo *assembly*, mas aumentam o acoplamento e dificultam testes isolados e futuras separações em projetos distintos.

2.5 Modelo de dados

A persistência do RadarTorres foi igualmente documentada por meio de um levantamento do modelo de dados diretamente a partir do código-fonte já implementado. O protótipo não depende de um servidor de banco de dados: utiliza **SQLite** (`Microsoft.Data.Sqlite`, arquivo único `radartorres.db` na pasta de dados do usuário), com `PRAGMA foreign_keys = ON` garantindo chaves estrangeiras reais – estágio mais avançado do que o modelo em CSV descrito em versões anteriores deste documento (ver nota histórica adiante). O schema atual tem onze tabelas, listadas na Tabela 3: sete cadastrais/de auditoria, já cobertas pelo levantamento em `conteudo_modelo_banco_dados.tex` (pasta `Banco_de_Dados` dos documentos entregáveis), e quatro exclusivas do treinamento neuroevolutivo, que persistem a evolução do controlador híbrido (Seção 2.3.5) entre execuções.

O modelo de dados atual (SQLite, 11 tabelas, chaves estrangeiras reais) é apresentado a seguir em três grupos, por legibilidade: o núcleo de usuários e preferências (Figura 8), o núcleo de detecção, câmeras e auditoria (Figura 9) e as tabelas de treinamento neuroevolutivo, independentes entre si (Figura 10) – diagramas entidade-relacionamento levantados a partir do código-fonte do projeto.

`usuarios` se relaciona 1:1 com `preferencias_usuario` (chave `UsuarioId` → `usuarios.Id`) e 1:N com `modo_atual_torre` (`ID_USER` → `usuarios.Id`) – em ambos os casos por chave estrangeira real de inteiro, não mais por login em texto. `objetos_detectados` se relaciona 1:N com `acoes_realizadas` (quando há alvo associado ao acionamento), com `ocorrencia_estados` (histórico de transição de estado) e com `classificacoes_alvo` (`ObjetoDetectadoId` → `objetos_detectados.Id`); `cameras` se relaciona 1:N com `objetos_detectados` pelo quadrante monitorado. As quatro tabelas de treinamento não se relacionam por FK com as demais nem entre si: são séries temporais independentes, cada uma identificada pelo número da geração (`GERACAO`/`GeracaoMarco`) e pelo instante de registro, cobrindo da granularidade mais fina (`historico_treinamento_geracoes`, uma linha por geração) à mais agregada (`instantaneos_comportamento_melhor_gene`, uma

Table 3: Tabelas do schema SQLite atual (`schema.sql` e os `Sqlite*Repository.cs`).

Tabela	**Finalidade**
`usuarios`	Contas de acesso, perfil (Administrador/Operador/Visualizador) e autenticação
`objetos_detectados`	Histórico de ocorrências de detecção (radar e câmera, por quadrante)
`ocorrencia_estados`	Auditoria das transições de estado de cada ocorrência (só inserção)
`cameras`	Câmera responsável por cada quadrante (Q1–Q4)
`acoes_realizadas`	Auditoria de acionamentos efetivamente executados (só inserção)
`modo_atual_torre`	Auditoria de troca de modo de operação (só inserção)
`preferencias_usuario`	Preferências de interface por usuário (tema, idioma, sidebar)
`classificacoes_alvo`	Classificação de perigo do alvo por velocidade estimada, vinculada a `objetos_detectados` por FK
`historico_treinamento_geracoes`	Fitness (melhor e médio) e contagem de alvos abatidos/escapados a cada geração do algoritmo genético
`marcos_fitness_treinamento`	Agregado de fitness por bloco de gerações, para acompanhar a convergência do treino sem gravar geração a geração
`instantaneos_comportamento_melhor_gene`	Snapshot do comportamento do melhor indivíduo em marcos do treino: fitness, taxa de acerto, taxa de cobertura e o próprio genoma (JSON)

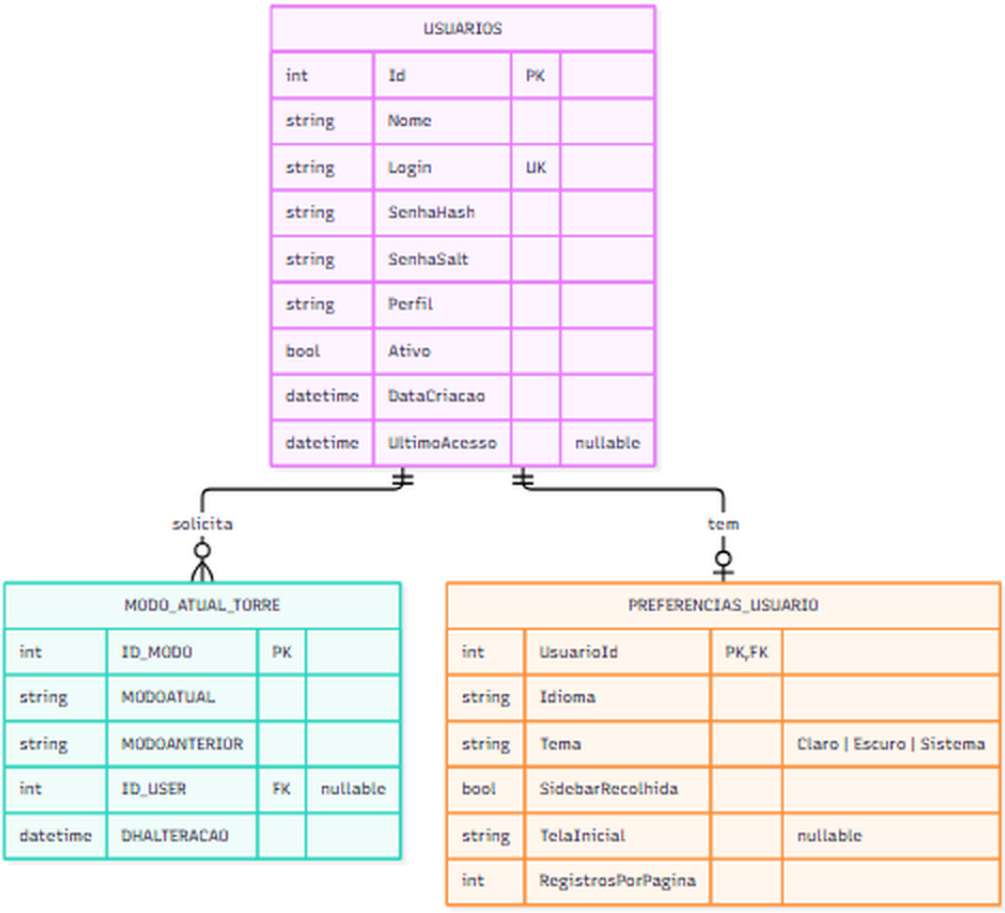


Figure 8: Núcleo de usuários: `usuarios`, `modo_atual_torre` e `preferencias_usuario` (dos autores).

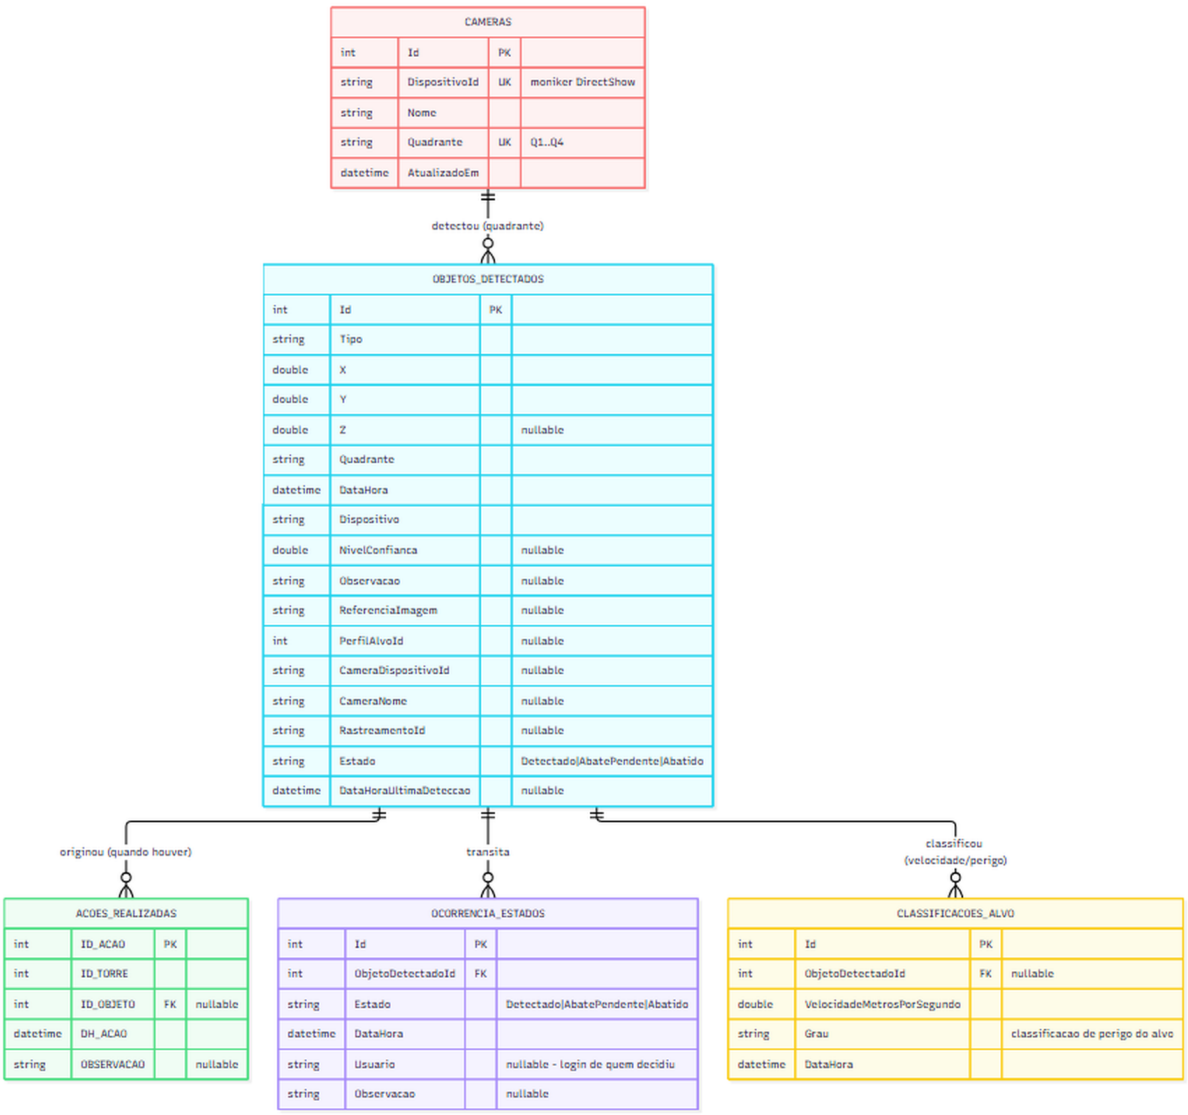


Figure 9: Núcleo de detecção e auditoria: `cameras`, `objetos_detectados`, `acoes_realizadas`, `ocorrencia_estados` e `classificacoes_alvo` (dos autores).

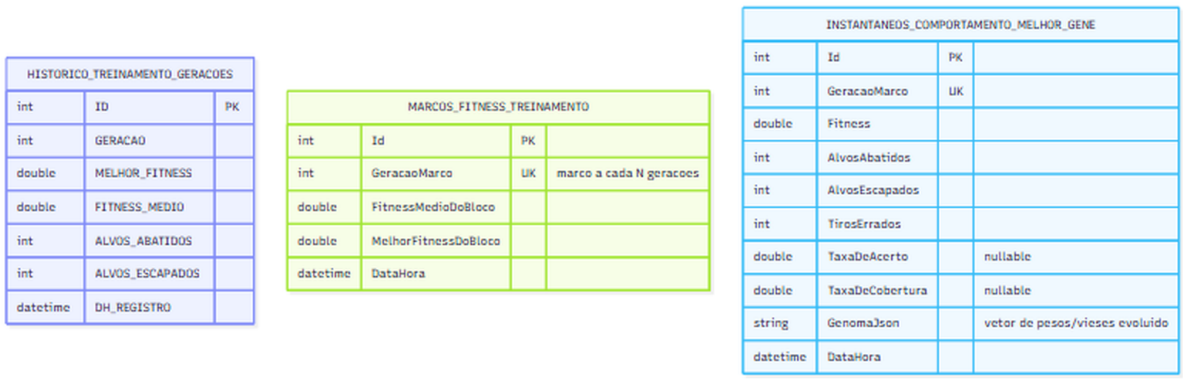


Figure 10: Tabelas de treinamento neuroevolutivo – séries temporais independentes entre si: `historico_treinamento_geracoes`, `marcos_fitness_treinamento` e `instantaneos_comportamento_melhor_gene` (dos autores).

linha por marco, com o genoma completo em JSON).

Como registro histórico do projeto, o modelo original em arquivos CSV tinha seis entidades (sem `ChamadoAjuda`, removida do código) e nenhuma chave estrangeira real – os vínculos entre `Usuario` e `AcaoRealizada`/`ModoAtualTorre` eram feitos por login em texto. A migração efetivamente realizada seguiu a proposta elaborada a partir desse modelo original para as sete entidades que já existiam, mas foi além dela ao acrescentar as quatro tabelas de treinamento neuroevolutivo, inexistentes na época em que a proposta foi desenhada.

3 Conclusão

Este trabalho descreveu o RadarTorres como um protótipo de rastreamento e seleção automática de alvos construído sobre sensoriamento ultrassônico, visão computacional e um controlador híbrido – heurística determinística que filtra e veta, rede neural pequena que decide dentro do espaço já validado, treinada por algoritmo genético. A contribuição mais original deste trabalho é empírica: a identificação e correção, documentada por commit, de uma falha em que a certeza de identificação do alvo era sorteada uma única vez e nunca atualizada, mantendo cerca de 70% dos alvos simulados permanentemente abaixo do limiar de disparo e mascarando a estagnação evolutiva sob a aparência de um treino funcional. A Tabela 1 (Seção anterior) quantifica o efeito dessa correção: o fitness médio da população, estagnado em torno de 9 ao longo de 25.500 gerações antes da correção, passou a acompanhar de perto o fitness do melhor indivíduo depois dela, e a cobertura de alvos disparáveis foi de uma fração minoritária para 100% nas amostras pós-correção.

As limitações do protótipo, discutidas ao longo do texto, concentram-se em três pontos: (i) o hardware físico ainda não foi montado – toda validação é feita em simulação, com modelos (certeza de identificação, probabilidade de erro de disparo) assumidos e não calibrados com dados de campo; (ii) a comunicação entre a visão computacional e o Arduino para guiar o apontamento de pan/tilt foi projetada mas não implementada, permanecendo como integração pendente; e (iii) a propriedade de projeto que limita o controlador híbrido, no pior caso, ao comportamento puramente heurístico (nunca a uma decisão arbitrária da rede) ainda não foi submetida a validação em hardware físico real.

Os trabalhos futuros identificados neste artigo são, portanto: montagem e validação do hardware físico das cinco torres; implementação do comando de apontamento no protocolo serial e da fusão entre a posição estimada pela visão e a distância ultrassônica; calibração dos modelos de certeza e de erro de disparo com dados de campo, substituindo as premissas simuladas; extensão da seleção de torre para a abordagem multiameaça da literatura de TEWA, hoje deixada de lado em favor da abordagem por proximidade; e, caso a capacidade da rede se mostre o fator limitante do controlador em vez dos hiperparâmetros da busca evolutiva, avaliação de uma arquitetura maior à luz dos resultados de Such et al. (2017).

Referências

ALSHIEKH, M. et al. *Safe Reinforcement Learning via Shielding*. 2017.

BAEK, I. et al. *CurbScan: Curb Detection and Tracking Using Multi-Sensor Fusion*. 2020.

HUANG, S.; ONTAÑÓN, S. *A Closer Look at Invalid Action Masking in Policy Gradient Algorithms*. 2020.

MAJONI, L. et al. Camera and ultrasonic sensor fusion for electronic travel aid: design and performance analysis. *MATEC Web of Conferences*, v. 417, p. 10005, 2025.

NAEEM, H. et al. *A Novel Two-Stage Dynamic Decision Support based Optimal Threat Evaluation and Defensive Resource Scheduling Algorithm for Multi Air-borne threats*. 2009.

NAEEM, H. et al. *A Novel Two-Staged Decision Support based Threat Evaluation and Weapon Assignment Algorithm, Asset-based Dynamic Weapon Scheduling using Artificial Intelligence Techniques*. 2009.

SUCH, F. P. et al. *Deep Neuroevolution: Genetic Algorithms Are a Competitive Alternative for Training Deep Neural Networks for Reinforcement Learning*. 2017.