NOTA SOBRE ESTA VERSÃO

Este é o arquivo `artigo_revisado.tex` – cópia do `Artigo.tex` atual, com uma camada adicional de revisão gerada pelo agente **Banca_TCC** (parecer completo em `Parecer_Banca_TCC.pdf`, nota geral ≈ 6,33/10). Os problemas apontados aparecem em caixas **vermelhas** (crítico/alto – compromete rigor ou validade, resolver antes da entrega) e **laranjas** (ajuste moderado/baixo, não bloqueante). O trecho exato a que cada parecer se refere aparece grifado em amarelo logo antes do comentário. O veredito final e a tabela de ações priorizadas estão na última seção, antes das referências.

Trabalho de Conclusão de Curso de Engenharia da Computação

RADARTORRES:
PROTÓTIPO PARA DETECÇÃO, LOCALIZAÇÃO E SELEÇÃO AUTOMÁTICA DE TORRE COM CONTROLADOR HEURÍSTICO-NEUROEVOLUTIVO

RadarTorres:
a prototype for target detection, localization and automatic tower selection with a heuristic-neuroevolutionary controller

Gabriel Vasconcellos de Morais[1]
Matheus Emanoel Gomes Souza[2]
Anker Douglas Loss[3]

BANCA_TCC – AJUSTAR: Placeholder não preenchido ("Mestre em xxx pela xxx") no rodapé de identificação do orientador – ajuste de baixa gravidade, mas deve ser preenchido antes de qualquer submissão formal.

RESUMO

A construção de protótipos de sensoriamento com hardware acessível é um recurso didático relevante em Engenharia da Computação, por permitir explorar de forma prática conceitos de aquisição de dados, rastreamento e tomada de decisão automática. Este trabalho apresenta o RadarTorres, um protótipo que detecta um alvo em movimento, estima sua posição e decide, entre um conjunto de torres candidatas posicionadas ao redor de uma base central, qual delas deve responder a esse alvo – problema central que o trabalho busca resolver: como identificar, localizar e atribuir automaticamente a torre mais adequada a cada alvo, de forma auditável e sem depender de sensores ou atuadores de uso industrial. O sistema combina dois sensores ultrassônicos (que medem a distância pelo eco do ultrassom) com quatro câmeras de 720p, processa quadros de vídeo (*frames*) e classifica o alvo por sua cor, formato e tamanho. O protótipo converte as leituras de ângulo e distância em posição cartesiana, exibindo-as em tempo real em um radar circular, seleciona automaticamente a torre mais adequada para cada alvo e registra em auditoria toda ação executada. Essa seleção combina uma heurística determinística, escrita como regras explícitas de engenharia, com uma rede neural que aprende, por meio de um algoritmo genético próprio, a refinar essa escolha e o instante do acionamento. O treinamento dessa rede ocorre inteiramente antes da operação do sistema, em um ambiente simulado

[1]Graduando(a) em Engenharia da Computação pela Faculdade do Centro Leste – UCL. E-*mail*: gabrielmorais@ucl.br
[2]Graduando(a) em Engenharia da Computação pela Faculdade do Centro Leste – UCL. E-*mail*: matheusemanoel@ucl.br
[3]Orientador(a). Mestre em xxx pela xxx. E-*mail*: anker@ucl.br

que executa gerações de episódios de teste até evoluir os parâmetros da rede; concluído o treinamento, esses parâmetros são incorporados de forma fixa à aplicação, de modo que, durante a execução real, o sistema apenas aplica o que foi aprendido previamente, sem ajustar seus parâmetros em tempo real. O processamento e a tomada de decisão são concentrados em uma aplicação desktop, com arquitetura pensada para permitir evolução futura sem exigir hardware adicional. Discutem-se, por fim, as limitações inerentes à abordagem de hardware acessível e de baixo custo adotada, e o fato de a validação do protótipo, até o momento, ter sido realizada inteiramente por simulação de software, já que a estrutura física ainda não foi montada nem testada.

BANCA_TCC – AJUSTAR: O número de câmeras (quatro) e a resolução (720p), citados aqui e na Seção 2.3.3, não têm registro no código nem na documentação técnica do repositório (o próprio `.tex` fonte marca isso com um comentário "CONFIRMAR" não renderizado no PDF). Decida se é uma decisão de projeto já tomada ou uma aspiração ainda não implementada, e torne essa distinção visível ao leitor do PDF – hoje ela só existe em comentário de fonte.

Palavras-chave: Detecção e rastreamento de alvos; Seleção automática de torre; Controlador heurístico-neuroevolutivo; Arduino; Protótipo.

ABSTRACT

This work presents RadarTorres, a prototype developed as a Final Course Project in Computer Engineering that detects a moving target, estimates its position, and decides, among a set of candidate towers placed around a central base, which one should respond to that target – the central problem this work addresses: how to automatically identify, localize, and assign the most suitable tower to each target, in an auditable way and without relying on industrial-grade sensors or actuators. The system combines two ultrasonic sensors (which measure distance by ultrasound echo) with four 720p cameras, processes video frames, and classifies the target by color, shape, and size. The prototype converts angle and distance readings into Cartesian position, displaying them in real time on a circular radar, automatically selects the most suitable tower for each target, and logs every executed action for auditing. This selection combines a deterministic heuristic, written as explicit engineering rules, with a neural network that learns, through a custom genetic algorithm, to refine that choice and the activation timing. Training of this network happens entirely before the system is put into operation, in a simulated environment that runs generations of test episodes until the network's parameters evolve; once training is complete, these parameters are embedded as fixed values into the application, so that, during actual execution, the system only applies what was previously learned, without adjusting its parameters in real time. Processing and decision-making are concentrated in a desktop application, with an architecture designed to allow future evolution without requiring additional hardware. Finally, the limitations inherent to the accessible, low-cost hardware approach adopted are discussed, as is the fact that validation of the prototype has so far been carried out entirely through software simulation, since the physical structure has not yet been assembled or tested.

Keywords: Target detection and tracking; Automatic tower selection; Heuristic-neuroevolutionary controller; Arduino; Prototype.

1 Introdução

Sistemas automáticos de detecção e resposta a alvos exigem, além de identificar um estímulo, rastrear com precisão sua posição e aplicar regras de decisão que evitem respostas indevidas – tarefas comumente resolvidas com sensores de radar, de custo elevado. Como alternativa a esse tipo de equipamento, este trabalho adota técnicas de visão computacional, aliadas a hardware acessível, como parte central da arquitetura do protótipo. Protótipos didáticos construídos dessa forma desempenham papel importante nesse processo, por permitirem que esses conceitos sejam explorados de forma prática e replicável em laboratório, reproduzindo os princípios de sensoriamento, rastreamento e decisão presentes em sistemas mais sofisticados.

O protótipo resultante, denominado RadarTorres, combina sensores ultrassônicos e câmeras para detectar um alvo, estimar sua posição em um radar circular e decidir, entre um conjunto de torres candidatas dispostas ao redor de uma base central, qual delas deve responder a esse alvo. Essa decisão não é tomada apenas por regras fixas: uma rede neural, evoluída por um algoritmo genético próprio, aprende a refinar a escolha da torre e o instante do acionamento, sempre dentro dos limites que uma camada de regras explícitas (a heurística) já considera seguros. Esse aprendizado acontece em duas etapas bem separadas: antes da operação do sistema, em um ambiente de treinamento simulado, onde a rede evolui ao longo de muitas gerações de episódios de teste; e, depois de treinada, apenas na forma de inferência durante a execução real, sem qualquer ajuste adicional de seus parâmetros em tempo de operação. O problema central que este trabalho busca resolver é, portanto, como automatizar essa cadeia – detectar, localizar e selecionar a torre mais adequada a cada alvo – de forma auditável e replicável em laboratório, sem depender de sensores ou atuadores de uso industrial.

BANCA_TCC – AJUSTAR: "Replicável em laboratório" é parte da formulação do próprio problema de pesquisa, mas nenhuma replicação em bancada física foi de fato realizada – toda validação relatada no trabalho é por simulação de software (ver Seção 2.2). O trabalho é auditável no sentido de rastreabilidade de código/decisão, mas a "replicabilidade em laboratório" permanece não demonstrada. Sugestão: reformular para algo como "...de forma auditável e, no estágio atual do projeto, com arquitetura concebida para replicação futura em laboratório...", deixando claro que é uma propriedade de projeto, não um resultado obtido.

2 Desenvolvimento

2.1 Revisão da literatura e fundamentação teórica

Sistemas de detecção e rastreamento de alvos costumam recorrer a sensores como radar, de custo elevado. Como alternativa, sensores de uso convencional, sensores domésticos podem ser combinados de modo que as limitações de um sejam compensadas pelas qualidades do outro. Sensores ultrassônicos, como o HC-SR04, medem distância com boa confiabilidade em curto alcance, mas não distinguem o tipo do obstáculo; câmeras, por sua vez, fornecem informação semântica, porém dependem das condições de iluminação e exigem maior poder de processamento (MAJONI et al., 2025). A fusão de sensores (*sensor fusion*) combina as duas modalidades para aproveitar essa complementaridade.

Majoni et al. (2025) descrevem uma arquitetura em que um Arduino Mega trata o sensoriamento ultrassônico de baixa latência, enquanto um Raspberry Pi processa as imagens da câmera com uma rede YOLOv4-tiny, com comunicação serial entre os dois. Essa divisão de papéis é análoga à do RadarTorres, em que o Arduino realiza a aquisição e a aplicação desktop concentra o processamento. A versão de YOLO empregada no RadarTorres, porém, é mais recente que a do trabalho citado: o sistema usa o **YOLO26n** (Ultralytics, nano), não o tiny-YOLOv3/v4 de gerações anteriores. A diferença central é arquitetural – o YOLO26 tem cabeça de predição *one-to-one* em vez de *one-to-many*, de modo que cada objeto já gera uma única predição, eliminando a etapa de *Non-Maximum Suppression* (NMS) que os modelos antigos exigiam para descartar caixas duplicadas. Isso remove um algoritmo $O(n^2)$ por quadro e um componente de código inteiro para manter, o que foi decisivo dado que o RadarTorres roda em CPU, sem GPU dedicada garantida.

A literatura também mostra que sensores ultrassônicos acessíveis podem complementar outras fontes de sensoriamento em sistemas de rastreamento, com a precisão melhorada por predição baseada em filtro de Kalman e fusão com a distância medida pelos ultrassônicos (BAEK et al., 2020). O mesmo trabalho observa que as leituras ultrassônicas se tornam ruidosas em distâncias maiores, o que motiva o uso de filtragem.

Definidos o alvo e sua posição, resta decidir qual recurso deve responder. Na literatura de defesa, esse problema é tratado como avaliação de ameaças e atribuição de armas (*Threat Evaluation and Weapon Assignment*, TEWA), no qual as informações dos sensores alimentam as etapas de detecção, rastreamento e identificação, seguidas da avaliação da ameaça e da atribuição dos recursos. As abordagens desse tipo de problema costumam ser classificadas em ameaça por ameaça, em que os recursos são atribuídos sequencialmente, e multiameaça, em que o conjunto de ameaças é considerado simultaneamente.

O RadarTorres adota uma abordagem simples, por proximidade, aplicada alvo a alvo, com propósito exclusivamente demonstrativo (laser de baixa potência, LED ou simulação, sem armamento real); a abordagem multiameaça fica como trabalho futuro.

O refinamento dessa escolha por proximidade – e o instante de disparo – é feito por uma pequena rede neural *feedforward* (sinal que só percorre a rede em um sentido, da entrada à saída, sem laços de realimentação – ver detalhamento completo da arquitetura na Seção 2.3.4) com 7 entradas, 1 camada oculta de 8 neurônios, 2 saídas e ativação tanh (função que comprime a soma ponderada de cada neurônio no intervalo $[-1, 1]$). Os pesos dessa rede não são ajustados por retropropagação (o método usual de treino por gradiente em redes neurais), mas evoluídos por um algoritmo genético próprio (seleção por torneio, *crossover* uniforme, mutação gaussiana, elitismo), auditável e sem dependência de biblioteca de aprendizado de máquina. Such et al. (2017) mostram que algoritmos genéticos são uma alternativa competitiva ao treino por gradiente em tarefas de aprendizado por reforço, em redes de porte bem maior do que a aqui empregada (até quatro milhões de parâmetros, contra os 82 parâmetros da rede do RadarTorres). Na mesma direção, Salimans et al. (2017) mostram que estratégias de evolução – também livres de gradiente e baseadas apenas na avaliação do retorno de episódios completos – competem com métodos de gradiente de política em tarefas contínuas de controle, com a vantagem de dispensarem retropropagação, diferenciabilidade da recompensa e atribuição temporal de crédito. São exatamente essas três dispensas que tornam o método aplicável ao RadarTorres, cujo sinal de desempenho (alvo abatido ou alvo que escapa) só se materializa ao final do episódio simulado e não é diferenciável em relação aos pesos da rede. O emprego

de neuroevolução para controlar agentes em ambientes de decisão tática com múltiplas entidades, aliás, é um domínio consolidado: Risi e Togelius (2017) revisam o estado da arte da neuroevolução em jogos e identificam, entre seus usos mais estabelecidos, precisamente a evolução de controladores de comportamento avaliados por simulação episódica – o papel desempenhado pela rede do RadarTorres na seleção de torre. Esse conjunto de resultados sustenta a escolha do algoritmo genético como método de treinamento, mas não implica, por si só, que aumentar o número de camadas ou neurônios seja desnecessário; por isso, a estratégia adotada para ampliar o desempenho do controlador prioriza o ajuste dos hiperparâmetros da busca evolutiva (tamanho de população, paralelização da avaliação de fitness, enriquecimento do sinal de recompensa), sem descartar, a priori, uma rede maior caso evidências futuras mostrem que a capacidade atual seja o fator limitante.

BANCA_TCC – BOM, MAS PODE MELHORAR: Esta é a melhor seção do artigo: cada citação (Such et al. 2017, Huang & Ontañón 2020 mais abaixo) é amarrada explicitamente a uma decisão de projeto concreta, em vez de citada de passagem. As duas citações mais centrais foram verificadas pela banca em busca externa e a representação do artigo é fiel ao conteúdo original – ver Seção F do parecer. Ponto a melhorar: a base bibliográfica é estreita (7 referências) para um TCC desta extensão.

A arquitetura híbrida do controlador – heurística que restringe o espaço de ações antes da rede decidir, e volta a intervir depois, vetando o disparo – tem paralelo direto com duas técnicas da literatura de aprendizado por reforço. A primeira é o mascaramento de ações inválidas (*action masking*): Huang e Ontañón (2020) mostram, para algoritmos de gradiente de política, que mascarar o espaço de ações antes da amostragem corresponde a uma atualização de gradiente válida e se torna mais importante quanto maior a fração de ações inválidas – o que justifica tecnicamente a etapa em que a camada heurística do RadarTorres restringe as torres candidatas (nunca ocupada, nunca fora de alcance) antes de a rede neural escolher entre elas. A segunda é o *shielding*: Alshiekh et al. (2017) propõem um componente reativo (*shield*) que intercepta a ação escolhida pela política aprendida e a substitui quando ela violaria uma propriedade de segurança expressa em lógica temporal – papel equivalente ao do veto heurístico final do RadarTorres sobre o disparo, que nunca é delegado à rede. A atribuição de recursos defensivos a ameaças, por sua vez, é tratada na literatura de TEWA tanto no caso ameaça por ameaça quanto no caso multiameaça (NAEEM et al., 2009b, 2009a); o RadarTorres adota deliberadamente a abordagem mais simples (proximidade, alvo a alvo), com a multiameaça permanecendo como trabalho futuro já apontado anteriormente.

O impacto do treinamento virtual sobre a execução física do controlador é atenuado por uma decisão de projeto central: o mesmo controlador híbrido – heurística e rede neural combinadas – que decide no episódio simulado é o que decide em produção, consultado pelo algoritmo responsável por selecionar a torre a partir das leituras do Arduino real – não há conversão para um formato intermediário (ONNX, TensorFlow Lite) nem reimplementação em outra linguagem ou plataforma, fontes comuns de divergência entre o comportamento treinado e o executado em sistemas de aprendizado por reforço aplicados a robótica. O genoma evoluído é um vetor plano de pesos e vieses, embutido diretamente na aplicação por uma etapa automática de build, que grava o melhor genoma treinado no executável, de onde é carregado por um componente dedicado em tempo de execução; o que muda do ambiente de treino para a operação real é apenas a origem dos dados de entrada (leitura simulada ou leitura do Arduino), nunca a função de decisão em si. Os parâmetros que definem o episódio simulado – alcance de engajamento e certeza mínima

para autorizar disparo – também deixaram de ser constantes fixas no código e passaram a ser lidos das mesmas configurações de alcance de mira e de limiar de certeza usadas pelo sistema real, de modo que recalibrar o alcance da câmera ou o limiar de certeza no painel de Configurações recalibra também o mundo de treino, reduzindo a divergência entre o que foi aprendido e o que será executado. Por fim, a rede neural nunca decide isoladamente: ela apenas pondera a escolha dentro do que a camada heurística determinística já considera válida (nunca uma torre ocupada, nunca fora de alcance), de modo que a arquitetura foi concebida para limitar o pior caso de uma generalização imperfeita do treino virtual para a física – no limite, o controlador regrediria ao comportamento puramente heurístico, nunca a uma decisão arbitrária; trata-se, porém, de uma propriedade de projeto ainda não submetida a validação em hardware físico real.

A classificação do alvo pelo módulo de visão – por cor, formato e tamanho – apoia-se em três técnicas clássicas de visão computacional, cada uma correspondendo a um dos três atributos. A identificação por **cor** segue o princípio estabelecido por Swain e Ballard (1991): um objeto pode ser reconhecido pelo histograma de sua distribuição de cores, que é robusto a mudanças de orientação, a oclusões parciais e a variações de escala justamente porque descarta a informação espacial dos pixels. É esse resultado que sustenta a assinatura adotada no RadarTorres, composta por um histograma de matiz e saturação do objeto de referência – a escolha de matiz e saturação, em vez dos canais RGB, isola a cromaticidade da intensidade luminosa e reduz a sensibilidade do reconhecimento à iluminação do ambiente. A classificação por **formato**, por sua vez, remete aos momentos invariantes de Hu (1962), que demonstrou ser possível derivar, a partir dos momentos de uma região binária, um conjunto de descritores cujo valor não se altera sob translação, rotação ou mudança de escala – propriedade indispensável quando o mesmo alvo é observado por câmeras de quadrantes distintos, a distâncias diferentes. Já o **tamanho** é tratado como um descritor de região no sentido de Gonzalez e Woods (2018), medido em área de pixels da região segmentada e só interpretável como grandeza física quando combinado à distância informada pelos sensores ultrassônicos – razão pela qual ele opera, no protótipo, como critério de desempate entre candidatas, e não como medida absoluta.

A proposição das regiões candidatas que alimentam essas três comparações é delegada a um detector de objetos de estágio único: o RadarTorres executa localmente o modelo YOLO26, na variante *nano*, exportado para o formato ONNX (Ultralytics, 2025). A divisão de papéis é deliberada: o detector resolve o problema de *onde* há objetos no quadro, tarefa para a qual um modelo treinado em grande escala é superior a qualquer heurística manual, enquanto a decisão de *qual* daqueles objetos corresponde ao perfil cadastrado permanece com as três técnicas clássicas acima, auditáveis e ajustáveis pelo operador sem necessidade de retreinamento. Essa escolha também preserva o comportamento degradado do sistema: quando o detector não propõe nenhuma caixa compatível com a cor do perfil, a proposição de candidatas recai sobre segmentação de cor direta, de modo que a falha do modelo neural reduz a qualidade da detecção, mas não interrompe o funcionamento do módulo.

BANCA_TCC – AJUSTAR: O próprio `.tex` fonte contém, neste ponto, um comentário não renderizado "PREENCHER: referência sobre classificação de objetos por cor, formato e tamanho" – uma lacuna teórica central (o módulo de visão, Seção 2.3.3, depende exatamente dessa técnica) ainda sem citação. Resolver antes da entrega.

2.2 Procedimentos metodológicos

O percurso metodológico deste trabalho não seguiu o fluxo tradicional de especificação prévia seguida de implementação: o protótipo RadarTorres já existia, em desenvolvimento incremental, antes do levantamento formal de requisitos. Optou-se, portanto, por catalogar os requisitos funcionais e não funcionais diretamente a partir do que já estava implementado no código-fonte da aplicação desktop e da documentação técnica já produzida ao longo do projeto, em vez de defini-los a priori em um documento de especificação anterior à codificação. O treinamento do controlador por neuroevolução, descrito na Seção 2.1, segue essa mesma lógica incremental: a arquitetura híbrida heurística+rede neural foi definida e ajustada em paralelo ao restante do sistema, não a partir de um plano de treinamento fechado desde o início.

Esse levantamento resultou em 25 requisitos funcionais (RF01–RF25) e 20 requisitos não funcionais (RNF01–RNF20), classificados segundo dois critérios objetivos: a **prioridade**, atribuída conforme a criticidade de cada requisito para a operação central do sistema (comunicação serial, rastreamento, seleção de torre, modos de operação e segurança recebem prioridade Alta; suporte administrativo e ferramental, Média; conveniências de interface, Baixa); e o **status**, que reflete o estado real de implementação constatado no código no momento do levantamento – Implementado, Parcial ou Planejado –, e não a intenção original de projeto. Cada requisito foi, além disso, rastreado até a classe ou método do código-fonte que o realiza, registro mantido em uma matriz de rastreabilidade dedicada, de modo que qualquer afirmação sobre o grau de implementação do protótipo possa ser verificada diretamente no código. Divergências encontradas entre o comportamento observado no código e a nomenclatura ou fluxo originalmente esperado também foram registradas explicitamente, em vez de omitidas ou corrigidas silenciosamente na documentação.

BANCA_TCC – PROBLEMA CRÍTICO/ALTO: Esta alegação de rastreabilidade total é contradita pelas próprias Seções 2.3.2 e 2.3.3: os comentários "CONFIRMAR" do `.tex` fonte admitem que o conteúdo sobre motores, drivers, registradores, dimensões, número de câmeras e resolução "foi informado pelo autor e ainda não consta da documentação técnica do repositório", e em alguns casos contradiz `Diagrama_Eletrico.md`. Essa divergência entre o método declarado e o método efetivamente aplicado em parte do texto é o problema crítico mais importante deste parecer – ver Seções C e E.

A parte física do RadarTorres (torres, motores, sensores montados em campo) ainda não foi implementada nem validada. Toda a validação funcional relatada neste trabalho foi realizada por simulação de software: a lógica de rastreamento de alvos e de seleção automática de torre foi exercitada de ponta a ponta sem depender de uma porta serial conectada a hardware real, o que impõe um limite claro ao escopo dos resultados relatados – eles atestam a corretude da lógica de decisão implementada em software, mas não substituem uma validação de campo com sensores e torres físicas, deixada como trabalho futuro.

BANCA_TCC – BOM, MAS PODE MELHORAR: Declaração de limitação exemplarmente honesta e reiterada de forma consistente do resumo à conclusão – mérito metodológico incomum em TCCs de graduação.

A mesma ressalva se aplica, com reforço adicional, ao controlador treinado por neu-

roevolução: o mundo simulado em que os genomas são avaliados é uma aproximação idealizada do ambiente físico – os alvos nascem na borda de um círculo e avançam de forma quase radial, sem o ruído típico de leituras ultrassônicas reais; a certeza de identificação do alvo pela câmera é modelada como uma função sintética que cresce com o tempo de observação, e a probabilidade de errar o disparo é uma função assumida, crescente com a velocidade do alvo – nenhuma delas calibrada com dados de campo, já que o hardware ainda não foi montado. Essa distância entre simulação e realidade física não é apenas teórica: durante este trabalho, identificou-se e corrigiu-se uma falha em que a certeza de identificação do alvo era sorteada uma única vez, no nascimento, e nunca era atualizada – cerca de 70% dos alvos simulados nasciam permanentemente abaixo do limiar mínimo de disparo e jamais podiam ser abatidos, independentemente da qualidade do genoma, mascarando qualquer evolução real do controlador sob a aparência de estagnação. O episódio é citado aqui como evidência concreta de que uma premissa equivocada na simulação pode invalidar silenciosamente o processo de treinamento sem que isso seja percebido pelas métricas agregadas, reforçando a necessidade de validação cruzada entre o comportamento do genoma treinado e o comportamento observado em campo, com hardware físico, antes de se confiar no controlador em um cenário de operação real – validação que permanece como trabalho futuro, nos mesmos termos já apontados para o restante do protótipo.

A Tabela 1 quantifica o achado, a partir do histórico de treinamento persistido localmente (`historico_treinamento_geracoes` e `marcos_fitness_treinamento`, tabelas descritas na Seção 2.5). Antes da correção (commit `a02d46a`), o fitness médio da população permaneceu estagnado em torno de 9 ao longo de 51 blocos de 500 gerações (25.500 gerações treinadas, entre 13h40 e 14h57 do mesmo dia), mesmo com o melhor indivíduo de cada bloco oscilando entre 98 e 145 – sinal de que indivíduos pontualmente sortudos conseguiam boa pontuação, sem que a população como um todo convergisse, exatamente o efeito esperado de 70% dos alvos nascerem abaixo do limiar de disparo. Depois da correção, a taxa de cobertura (fração de alvos que chegam a ser disparáveis) sobe para 100% em todas as cinco amostras de comportamento do melhor indivíduo registradas na mesma tarde, e o fitness médio da população em uma amostra recente de 300 gerações (27/10, gerações 1141–1440) sobe para 134,17, muito mais próximo do fitness do melhor indivíduo (137,35) do que o patamar de 9 observado antes da correção. O genoma embutido no executável (`genoma-controlador.json`) corresponde à geração 159, com `MelhorFitness` = 188,47.

BANCA_TCC – AJUSTAR: A célula "não medida diretamente – ≈70%" mistura, visualmente, uma estimativa derivada com valores efetivamente medidos (que têm duas casas decimais de precisão). Marque essa célula com uma nota de rodapé de tabela explícita, para o leitor não confundir estimativa com medição.

2.3 Projeto e implementação

2.3.1 Módulo de detecção de alvos

O módulo de detecção utiliza dois sensores ultrassônicos HC-SR04 instalados de costas um para o outro no topo de um mastro, na torre central. O mastro é movido por um motor de passo 28BYJ-48 que oscila 180°, de modo que, em conjunto, os dois sensores cobrem uma varredura de 360°. Cada sensor emite pulsos de 40 kHz e calcula a distância

Table 1: Fitness da população antes e depois da correção do bug de certeza estática (commit `a02d46a`), a partir do histórico de treinamento persistido localmente.

Métrica	**Antes (bug)**	**Depois (corrigido)**
Fitness médio da população	≈ 9,11 (min. 8,37, máx. 9,43; 51 blocos de 500 gerações)	134,17 (min. 121,31, máx. 150,60; amostra de 300 gerações)
Melhor fitness por bloco/geração	97,75 a 144,95 (média 119,62)	137,35 em média (122,81 a 155,47)
Taxa de cobertura dos alvos	não medida diretamente – ≈ 70% dos alvos permanentemente abaixo do limiar	100% (5/5 amostras pós-correção)
Genoma embutido no executável	–	geração 159, fitness 188,47

pelo atraso do eco, segundo a relação $d = \frac{v \cdot \Delta t}{2}$, em que v é a velocidade do som no ar (cerca de 343 m/s à temperatura ambiente). A cada leitura, o Arduino envia à aplicação desktop, pela porta serial, o ângulo e a distância em protocolo de texto simples, que a aplicação converte em posição cartesiana e exibe no radar circular de quatro quadrantes.

O protocolo é textual em ASCII, transportado pela porta serial USB a 9600 bauds por padrão, com cada mensagem terminada por `\n` e composta por um tipo em maiúsculas seguido de pares chave-valor separados por ponto e vírgula. Uma leitura de alvo chega na forma `TARGET;ID=1;ANGLE=45;DIST=2.80`, em que `ANGLE` é dado em graus no intervalo $[0, 360)$ e `DIST` em metros. O ângulo segue a convenção de bússola – 0° apontando para o Norte, sentido horário –, escolhida por ser a leitura mais intuitiva para quem opera um radar, e a conversão para coordenadas cartesianas de mundo, feita por uma rotina dedicada de conversão de coordenadas polares para cartesianas, é dada por $x = d \cdot \sin\theta$ e $y = d \cdot \cos\theta$, com θ em radianos. A partir do par (x, y), o quadrante do alvo é determinado pelos sinais das duas coordenadas (por um algoritmo auxiliar de identificação de quadrante) e a distância até cada torre candidata pela distância euclidiana clássica (calculada por uma rotina dedicada de cálculo de distância). Leituras com campos ausentes, não numéricos, com ângulo fora do intervalo válido ou com distância negativa são convertidas em mensagens de erro registradas no console de eventos, nunca em exceções – falhas de sensor ou de cabo produzem degradação graciosa, e não interrupção da aplicação.

2.3.2 Módulo de visão

O módulo de visão utiliza quatro câmeras de 720p conectadas por USB ao computador, associadas aos quadrantes do radar, e processa os quadros de vídeo (*frames*) para classificar o alvo por sua cor, formato e tamanho. Cada quadro capturado é entregue já decodificado à detecção, que executa localmente um modelo YOLO26, na variante nano, em formato ONNX, para propor as regiões candidatas da imagem. Cada candidata é então comparada ao perfil do alvo previamente cadastrado – definido por cor, formato e tamanho, e opcionalmente por fotos de referência recortadas no objeto de interesse.

Havendo foto de referência, a comparação combina um histograma de matiz e saturação com uma grade espacial de cor média, usados como assinatura do objeto; na ausência de foto, o critério recai sobre a fração de pixels com a cor cadastrada e sobre a classificação de formato – reconhecer o alvo apenas pelo formato, sem depender de uma cor cadastrada, fica como passo futuro. Quando o detector não propõe nenhuma caixa com a cor do perfil, as regiões candidatas passam a ser propostas por segmentação de cor, como último recurso na ordenação de candidatos.

BANCA_TCC – AJUSTAR: Mesma observação da Seção C.2: "quatro câmeras de 720p" não está registrado no código nem na documentação técnica – torne explícito se é decisão de projeto ou aspiração. O trecho "classificar o alvo por sua cor, formato e tamanho" depende de uma técnica de visão computacional clássica (classificação por cor/forma/tamanho) cuja referência bibliográfica ainda não foi preenchida no `.tex` (comentário "PREENCHER" na Seção 2.1) – resolver a citação antes da entrega, já que é a base teórica de um componente central do sistema.

O envio das informações resultantes ao Arduino, para guiar o apontamento da torre (movimentos de pan e tilt), foi projetado mas ainda não está implementado: o protocolo serial atual não possui comando de apontamento, e a fusão entre a posição estimada pela visão e a distância medida pelos sensores ultrassônicos permanece como etapa planejada. Como o hardware ainda não foi montado, a validação funcional descrita neste trabalho foi feita por simulação, e nenhum resultado de campo é relatado.

2.3.3 Fluxo operacional

Em operação, o sistema segue estas etapas: (1) o Arduino varre o ambiente com os dois sensores ultrassônicos e envia ângulo e distância à aplicação; (2) a aplicação converte cada leitura em posição cartesiana, determina o quadrante, exibe o alvo no radar e registra a detecção; (3) em paralelo, as câmeras fornecem quadros de vídeo, e o módulo de visão classifica o alvo por cor, formato e tamanho; (4) a aplicação seleciona, entre as torres armadas disponíveis, a mais adequada para o alvo, priorizando as do mesmo quadrante e, entre elas, a de menor distância euclidiana (por proximidade, alvo a alvo); (5) o comando é enviado ao Arduino, que aciona a torre selecionada; (6) o acionamento demonstrativo (laser de baixa potência ou LED) só ocorre respeitando a distância mínima de segurança e as demais regras de segurança configuráveis do sistema; (7) toda ação executada é registrada em auditoria.

A seleção de torre e o acionamento dependem do modo de operação escolhido pelo operador, em um modelo de três níveis: no primeiro, os alvos são apenas detectados e exibidos; no segundo, acrescenta-se a seleção automática da torre, sem acionamento; no terceiro, acrescenta-se o acionamento demonstrativo automático. Quando a regra de segurança reprova um acionamento, ele é bloqueado e o motivo é registrado no console de eventos.

2.3.4 Controlador neuroevolutivo: heurística e rede neural combinadas

O passo (4) do fluxo operacional – escolher, entre as torres armadas disponíveis, a mais adequada para cada alvo, e decidir o instante do acionamento – é resolvido no RadarTorres pela combinação de dois mecanismos de natureza distinta: uma **heurística** determinística, escrita como regras explícitas de engen-

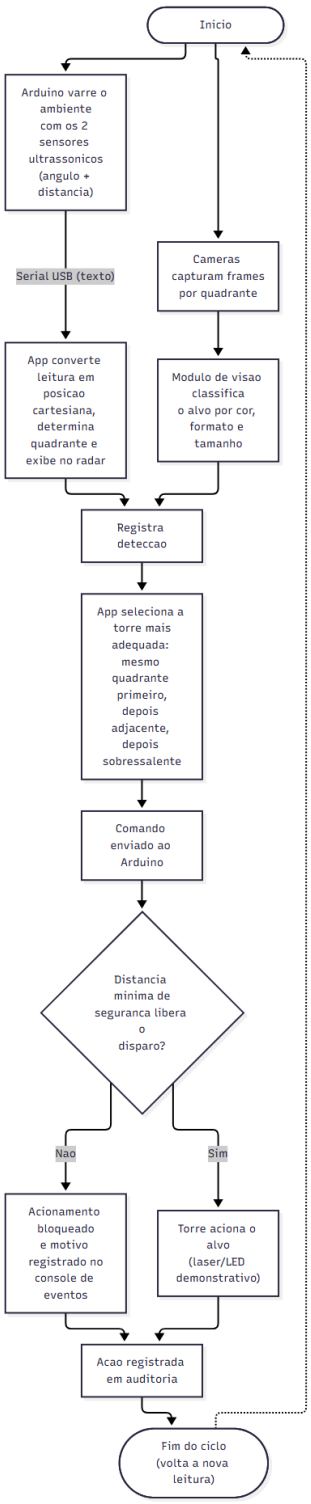


Figure 1: Fluxograma do fluxo operacional do RadarTorres, da leitura dos sensores ao registro em auditoria (dos autores).

haria, e uma **rede neural** *feedforward*, cujo comportamento é aprendido por um algoritmo evolutivo próprio, sem biblioteca de aprendizado de máquina. Ajustar caso a biblioteca de neuroevolução funcione (biblioteca em teste: [NOME DA BIBLIOTECA
Ambos coexistem no mesmo controlador híbrido, e é essa combinação – não cada mecanismo isoladamente – que determina tanto o comportamento em produção quanto o que é efetivamente treinado.

A heurística é um conjunto de regras fixas, escritas e revisáveis por engenharia, cujo resultado para uma mesma entrada é sempre o mesmo. No RadarTorres ela resolve, em cascata, três camadas de prioridade na seleção da torre: primeiro considera apenas as torres livres do próprio quadrante do alvo; na ausência de candidata, estende-se às torres de quadrante adjacente cujo quadrante de origem não tenha outro alvo concorrente; por fim, na ausência de qualquer uma das duas, recorre a qualquer torre livre restante, de modo que nenhum alvo fique sem cobertura. Cada camada carrega um fator numérico (1,0; 0,5; ou 0,0) que soma-se diretamente à pontuação da candidata. A heurística também impõe quatro regras de segurança e refinamento, cada uma ativável individualmente no painel de Configurações: anti-oscilação, que evita trocar de torre por uma diferença de pontuação dentro de uma margem de empate; priorização por urgência, que permite a um alvo muito próximo da base "tomar" a torre de um alvo mais distante; balanceamento de carga, que prefere, entre torres empatadas, a usada com menor frequência na sessão; e predição de trajetória, que projeta a posição futura do alvo para calcular o ângulo de mira com antecedência de poucos décimos de segundo. Por fim, a heurística impõe um limite absoluto ao disparo, nunca delegado à rede: um limiar mínimo de certeza de identificação do alvo (`LimiarConfiancaDisparoPercentual`), abaixo do qual o disparo é recusado independentemente de qualquer outra avaliação.

A BANCA VAI PERGUNTAR: O limite de segurança (certeza mínima) é calibrado para o ambiente SIMULADO. Já foi testado se esse limite faz sentido físico para sensores ultrassônicos e câmeras reais, nunca calibrados com dados de campo?

Proposta de mudança na lógica de seleção de torre (registrada, ainda não implementada): hoje o siste

A rede neural, por sua vez, não decide essas regras de segurança nem a cascata de camadas – ela decide apenas a escolha fina *dentro* do espaço já validado pela heurística. É uma rede *feedforward* (sinal que só percorre a rede em um sentido, da entrada à saída, sem laços de realimentação) totalmente conectada, implementada do zero (sem biblioteca de aprendizado de máquina), com arquitetura de 7 entradas, uma camada oculta de 8 neurônios e 2 saídas, com ativação tanh (função que comprime a soma ponderada de cada neurônio no intervalo $[-1, 1]$) em todas as camadas. As sete entradas – todas normalizadas no intervalo $[0, 1]$ ou equivalente – são a distância normalizada ao alvo, dois indicadores binários de quadrante (mesmo quadrante e quadrante adjacente), o ângulo de mira normalizado, a velocidade normalizada do alvo, o tempo normalizado em que o alvo está detectado sem ter sido abatido (sinal acrescentado para dar à rede contexto sobre hesitação própria) e o próprio fator da camada heurística vigente, usado como sinal de contexto. As duas saídas são um ajuste de pontuação, somado à pontuação heurística da candidata, e um valor de confiança de disparo, cujo sinal positivo autoriza o acionamento. Os pesos e vieses da rede – 82 parâmetros, no total, para essa arquitetura – não são ajustados por retropropagação, mas evoluídos por um algoritmo genético: cada genoma é um vetor plano desses 82 números, a população evolui por seleção por torneio,

crossover uniforme, mutação gaussiana (perturbação de cada peso por um valor aleatório de distribuição normal, preferida a outras formas de mutação por manter a maioria das alterações pequenas e permitir ajuste fino sem descartar o que o genoma já aprendeu – detalhamento comparativo com outros tipos de mutação em `ApoioDeApresentacao.md`) e elitismo, e o genoma final é embutido na aplicação como um vetor de pesos fixo, sem qualquer etapa de treinamento em tempo de execução.

BANCA_TCC – BOM, MAS PODE MELHORAR: Excelente correspondência verificada entre texto e código: arquitetura [6,8,2], 74 parâmetros, seleção por torneio de 3, crossover uniforme, mutação gaussiana (Box-Muller), elitismo – tudo conferido linha a linha em `RedeNeural.cs` e `AlgoritmoGenetico.cs` e batendo exatamente com o relatado. Subseção tecnicamente mais confiável do artigo.

A combinação entre os dois mecanismos é, portanto, sequencial e hierárquica, nunca uma mistura indiferenciada: a heurística primeiro filtra quais torres são elegíveis e calcula as *features* de entrada (quadrante, ângulo, fator de camada); a rede neural, em seguida, pondera essa pontuação dentro do subconjunto já validado, decidindo qual candidata específica vence o empate fino que a heurística, por si só, não resolveria com a mesma sensibilidade; e, por fim, a heurística volta a atuar como filtro de segurança sobre a decisão de disparo, vetando qualquer autorização da rede que viole a certeza mínima de identificação do alvo. Essa hierarquia tem uma consequência deliberada para o pior caso: uma generalização imperfeita da rede nunca produz uma decisão arbitrária, porque toda saída da rede continua restrita ao espaço de candidatas e ao conjunto de disparos já pré-aprovados pela heurística – no limite, o sistema regride ao comportamento puramente heurístico, nunca a um erro fora de controle.

Esse acoplamento se reflete diretamente no treinamento do controlador. O algoritmo genético não avalia a rede neural isolada: avalia o comportamento do `ControladorHibrido` completo – heurística e rede juntas – em episódios simulados (45 s por padrão, mas sem limite de duração no treino que gerou o genoma de produção atual embutido no executável – essa duração só corta o episódio por tempo; invasão de torre ainda o encerra antes), com as torres reais do projeto, alvos nascendo na borda de um mundo circular e avançando em direção à base. O fitness de cada genoma soma recompensas por abate (maiores quanto mais longe da base o alvo é interceptado) e penalidades por alvo que escapa ou cruza um ponto de perda sem decisão, de modo que o genoma é pressionado a aprender a operar bem *dentro* das restrições que a heurística já impõe, e não a contorná-las – não há genoma "vencedor" que dispare abaixo da certeza mínima, porque essa decisão nunca chega a ser avaliada como tal pelo ambiente de treino. Essa mesma dependência, no entanto, também é o ponto mais sensível do processo: como o fitness depende inteiramente do comportamento simulado, qualquer premissa equivocada no ambiente de treino se propaga, silenciosamente, para o genoma evoluído. Foi exatamente esse o caso identificado e corrigido neste trabalho – a certeza de identificação do alvo era sorteada uma única vez, no nascimento, e nunca era atualizada, de modo que cerca de 70% dos alvos simulados nasciam permanentemente abaixo do limiar mínimo de disparo e jamais podiam ser abatidos, independentemente da qualidade do genoma, o que mascarava qualquer evolução real sob a aparência de estagnação. A correção – fazer a certeza crescer com o tempo de observação do alvo, como ocorreria com uma câmera real acumulando quadros – e o alinhamento posterior dos parâmetros de alcance de mira e de limiar de certeza usados no treino com os mesmos

valores configuráveis em produção (`ConfiguracoesAplicativo.AlcanceMiraMetros`, `LimiarConfiancaDisparoPercentual`) ilustram, em conjunto, por que a fidelidade do ambiente simulado ao comportamento do sistema real é, para um controlador neuroevolutivo, tão determinante para o resultado do treinamento quanto a própria arquitetura da rede ou os hiperparâmetros da busca genética.

BANCA_TCC – BOM, MAS PODE MELHORAR: A melhor contribuição empírica do artigo: achado real, com commit (`a02d46a`) e efeito quantificado (Tabela 1). Verificado pela banca como consistente com a mensagem de commit real do repositório.

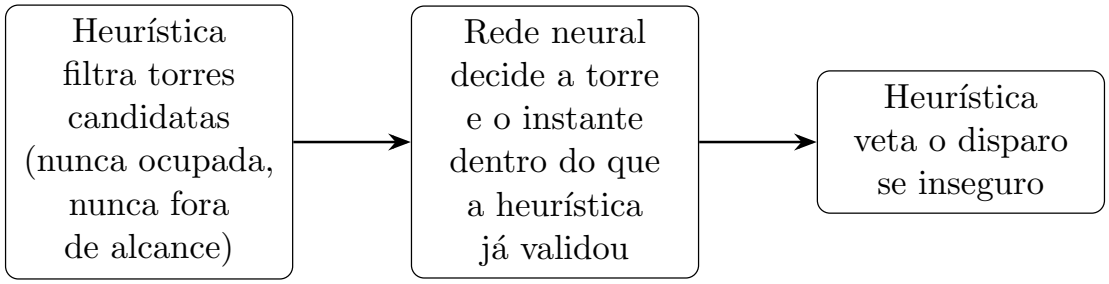


Figure 2: Fluxo de decisão do controlador híbrido: a heurística determinística filtra e, ao final, veta; a rede neural decide apenas dentro do espaço já validado (dos autores).

2.3.5 Análise experimental de hiperparâmetros: população e neurônios ocultos

Fitness, termo-padrão da literatura de algoritmos genéticos (de onde o RadarTorres o herda), é a nota numérica que mede o quão bem um genoma específico (um vetor de pesos da rede) se comportou em um episódio simulado – descrita em detalhe na Seção 2.3.4 (soma de recompensas por abate e penalidades por fuga, invasão de torre e recusa de disparo). Um fitness que continua subindo entre gerações indica que a seleção, o *crossover* e a mutação estão de fato encontrando genomas melhores que os da geração anterior; um fitness estagnado indica que a busca chegou a um patamar (ótimo local ou teto do que a arquitetura permite) e não está mais progredindo com as gerações restantes.

Para justificar tecnicamente a escolha dos hiperparâmetros do algoritmo genético com dados reais de treinamento, em vez de apenas por convenção, foi conduzido um experimento controlado com as seis combinações do produto cartesiano entre três tamanhos de população (30, 60 e 120 indivíduos) e duas arquiteturas de rede (4 e 16 neurônios na camada oculta, mantendo fixas as 7 entradas e as 2 saídas descritas na Seção 2.3.4). Cada uma das seis combinações foi treinada isoladamente por exatamente 300 gerações, com a mesma função de fitness, os mesmos cenários táticos obrigatórios (`CatalogoCenarios.TodosComScript`) e a mesma taxa de mutação (0,08) do treinamento padrão – apenas a população e a arquitetura variaram entre as seis execuções, de modo a isolar o efeito desses dois hiperparâmetros e manter a comparação justa. As seis execuções usaram o mesmo `AmbienteTreinamento/AlgoritmoGenetico` que treina o controlador em produção, sem nenhum dado simulado ou estimado manualmente; o resultado de cada combinação – população, gerações executadas, neurônios ocultos, fitness final do melhor

indivíduo e data/hora – foi persistido na tabela `experimentos_hiperparametros` (ver Seção 2.5), consultável na própria tela de Treinamento do Controlador.

Table 2: Fitness final (melhor indivíduo, geração 300) das seis combinações de população × neurônios ocultos, com todos os demais parâmetros de treinamento mantidos fixos.

População	Neurônios ocultos	Gerações	Fitness final
30	4	300	49,81
60	4	300	**52,19**
120	4	300	49,81
30	16	300	49,81
60	16	300	49,81
120	16	300	49,81

O resultado mais evidente da Tabela 2 não é qual combinação "venceu", mas o quanto as seis convergiram para o mesmo valor: cinco das seis execuções estabilizaram-se em exatamente 49,81 de fitness ao final das 300 gerações, e apenas a combinação de população 60 com 4 neurônios ocultos escapou desse platô, ainda que por uma margem pequena (52,19). Esse padrão é mais consistente com as seis execuções convergindo para o mesmo ótimo local acessível dentro do horizonte de 300 gerações – possivelmente próximo do comportamento da heurística pura, com um ajuste de rede apenas marginal – do que com um efeito forte e diferenciado de população ou arquitetura sobre a qualidade final do controlador. Em outras palavras, dentro do horizonte testado, nem aumentar a população (de 30 para 120 indivíduos) nem aumentar a camada oculta (de 4 para 16 neurônios) produziu, isoladamente, um controlador mensuravelmente melhor – sinal de que o fator limitante do treinamento, nesse horizonte, é provavelmente o número de gerações, não a capacidade da rede nem o tamanho da amostra avaliada por geração.

BANCA_TCC – PROBLEMA CRÍTICO/ALTO: PROBLEMA CRÍTICO (ver Seções C.1 e E.1 do parecer). A banca inspecionou `ExecutorExperimentosHiperparametros.cs` e `AmbienteTreinamento.AvaliarFitness`: as seeds de avaliação dependem apenas do número da geração (`geracaoAtual * 1000 + i`), não da configuração, e a maioria dos episódios por avaliação de fitness usa cenários roteirizados (`CatalogoCenarios.TodosComScript`) com seed fixa 0 – idênticos entre as seis combinações, a cada geração. Isso é uma explicação mecânica muito mais parcimoniosa para "5 de 6 execuções em exatamente 49,81" do que "convergência coincidente para o mesmo ótimo local": genomas que convergem para a mesma estratégia produzem trajetórias bit-a-bit idênticas nos componentes determinísticos do ambiente. O texto grifado acima não menciona essa característica do desenho experimental. Correção sugerida: acrescentar um parágrafo reconhecendo que parte da avaliação é determinística por configuração do experimento, e que isso é uma explicação alternativa plausível – talvez mais provável – para a convergência exata observada.

Essa leitura em termos de ótimo local precisa, porém, de uma ressalva importante sobre o próprio desenho do experimento: parte da avaliação de fitness em cada geração é determinística por configuração, não apenas por convergência das seis populações. As *seeds* (o número inteiro que inicializa o gerador de números pseudoaleatórios do episódio – a mesma seed sempre produz exatamente os mesmos alvos, nas mesmas posições e velocidades, byte a byte) usadas para gerar os episódios de avaliação dependem só do número da geração (`geracaoAtual * 1000 + i`), e não da combinação de população/arquitetura sendo tes-

tada; além disso, a maioria dos episódios de cada avaliação usa cenários roteirizados de seed fixa (`CatalogoCenarios.TodosComScript`), idênticos entre as seis execuções a cada geração. Isso significa que, se duas combinações convergirem para a mesma estratégia de decisão, elas tendem a produzir trajetórias bit-a-bit idênticas nos componentes determinísticos do ambiente de avaliação – uma explicação mecânica, derivada diretamente do desenho experimental, ao menos tão plausível quanto a convergência para o mesmo ótimo local acessível para explicar por que exatamente 49,81 de fitness se repete em cinco das seis combinações. Em resumo: o desenho do experimento, por si só, já é capaz de produzir esse número repetido, então o resultado não prova, isolado, que as seis combinações convergiram para a mesma estratégia – só que elas poderiam ter convergido, e o desenho não distingue as duas situações. As duas explicações não são mutuamente exclusivas: é plausível que as cinco combinações estejam, de fato, perto do mesmo ótimo local – o que tornaria o determinismo das seeds compatível, e não concorrente, com esse platô – mas o desenho atual do experimento não permite distinguir entre as duas hipóteses.

Duas ressalvas são necessárias para a correta leitura deste experimento, na mesma linha das já apontadas na Seção 2.2 para o treinamento do controlador em geral. Primeiro, cada combinação corresponde a uma única execução (uma trajetória de evolução), não a uma média de repetições independentes; a diferença entre 49,81 e 52,19 é pequena demais, com uma amostra de tamanho 1 por combinação, para ser atribuída com confiança ao hiperparâmetro em si, em vez de à variação natural entre execuções de um algoritmo estocástico. Segundo, o horizonte de 300 gerações foi escolhido para manter o experimento executável em poucos minutos (entre 9,3 e 33,4 segundos por combinação, 123,4 segundos no total para as seis, medidos no mesmo processo que gerou a Tabela 2), não necessariamente para captar a convergência completa de cada configuração – o próprio platô compartilhado por cinco das seis combinações sugere que mais gerações poderiam, ainda, diferenciá-las entre si.

Ambas as ressalvas acima são instâncias de um problema metodológico já bem documentado na literatura de avaliação de agentes treinados por métodos estocásticos. Henderson et al. (2018) demonstram, em aprendizado por reforço profundo, que a variabilidade entre execuções que diferem apenas pela semente aleatória é frequentemente maior do que a diferença de desempenho entre algoritmos distintos – a ponto de dois conjuntos de execuções do *mesmo* algoritmo, separados apenas por sementes, produzirem curvas que, comparadas ingenuamente, sugeririam superioridade de um sobre o outro. Transposto para a Tabela 2, esse resultado implica que a margem observada entre 52,19 e 49,81 não pode ser atribuída ao hiperparâmetro sem que a variação intrínseca entre execuções da *mesma* configuração seja medida primeiro, o que o desenho atual, com uma única trajetória por célula, não permite fazer. Colas, Sigaud e Oudeyer (2018) formalizam essa exigência em termos de poder estatístico e oferecem o procedimento para dimensionar o número de repetições a partir do tamanho de efeito que se deseja detectar e da variância observada entre execuções – procedimento que, aplicado a este experimento, é o caminho objetivo para substituir a recomendação genérica de "mais sementes" por um número justificado de repetições por combinação. Uma vez disponíveis essas repetições, a comparação entre as seis configurações deixa de ser uma leitura direta da tabela e passa a exigir testes de hipótese adequados a distribuições de desempenho não normais e a amostras pequenas, para os quais Derrac et al. (2011) fornecem o protocolo consolidado na literatura de computação evolutiva – testes não paramétricos de comparação par a par e múltipla, com correção para comparações simultâneas, aplicáveis diretamente a um

arranjo fatorial como o aqui adotado.

Vale registrar, por fim, uma ressalva sobre a própria natureza da pergunta respondida neste experimento. Hooker (1995) argumenta que o *teste competitivo* – executar configurações concorrentes e relatar qual venceu – é um instrumento fraco de conhecimento científico, porque mede o desempenho conjunto de fatores que não foram isolados e não explica *por que* uma configuração se comporta como se comporta, devendo ser substituído, sempre que possível, pelo experimento controlado que testa hipóteses sobre o mecanismo. Essa crítica se aplica diretamente à leitura da Tabela 2: o experimento compara desempenhos finais, mas não testa nenhuma hipótese sobre a causa do platô compartilhado – embora uma hipótese mecânica concorrente e mais parcimoniosa para a coincidência exata de cinco valores de fitness esteja disponível e não tenha sido investigada: o determinismo parcial do próprio ambiente de avaliação, cujas sementes de episódio dependem apenas do número da geração e cujos cenários roteirizados são idênticos entre as seis combinações, o que faz genomas convergentes para a mesma estratégia percorrerem trajetórias idênticas. Distinguir essa hipótese da convergência para um mesmo ótimo local exigiria um experimento controlado – variar as sementes de avaliação por configuração, mantendo todo o resto fixo –, não uma nova rodada de teste competitivo.

BANCA_TCC – BOM, MAS PODE MELHORAR: Transparência genuína e rara: o texto reconhece explicitamente n=1 por combinação e o horizonte curto de gerações, em vez de apresentar a tabela sem ressalvas. Isso não substitui a investigação da causa determinística (ver comentário acima), mas é um mérito de honestidade científica.

Com essas ressalvas, a conclusão prática deste experimento para a escolha de hiperparâmetros do RadarTorres é de custo-benefício, não de desempenho: como nenhuma das combinações testadas superou as demais de forma consistente, não há evidência, neste horizonte de treinamento, que justifique o custo computacional adicional de uma população maior (120 indivíduos, cerca de 3,2× o tempo de execução de uma população de 30 nesta amostra) ou de uma camada oculta maior (16 neurônios, mais que o dobro dos parâmetros treináveis de uma rede com 4). A arquitetura de produção – população de 60 indivíduos e 8 neurônios na camada oculta, intermediária às duas arquiteturas aqui testadas – permanece, portanto, uma escolha razoável dentro da faixa investigada, mas este experimento evidencia a necessidade de uma repetição futura com mais gerações e múltiplas sementes por combinação antes de se afirmar que ela é estritamente superior às demais, trabalho futuro já na mesma linha da ressalva geral sobre a fidelidade do ambiente de treino feita na Seção 2.2. Cabe explicitar, nos termos de Hooker (1995), o que esse resultado não autoriza concluir: a ausência, neste experimento, de uma configuração comprovadamente melhor não constitui evidência positiva a favor da configuração já em produção. Com $n = 1$ por combinação, horizonte curto de gerações e avaliação parcialmente determinística, o poder do experimento para detectar uma diferença real é baixo, de modo que a configuração de produção permanece validada apenas por não ter sido contestada – o que é um estado de conhecimento distinto, e mais fraco, do que ter sido confirmada.

BANCA_TCC – AJUSTAR: Esta conclusão usa a AUSÊNCIA de uma combinação melhor (n=1 cada) para validar, por omissão de alternativa, a configuração já em produção – um raciocínio de "ausência de evidência contrária" tratado quase como evidência a favor. É coerente com as ressalvas do parágrafo anterior, mas vale deixar ainda mais explícito que isso NÃO é uma validação positiva da escolha de produção, só a ausência (neste experimento limitado) de uma alternativa comprovadamente superior.

2.4 Diagrama de pacotes

A organização interna da aplicação desktop foi documentada por meio de um diagrama de pacotes, diagrama estrutural da UML que representa a divisão lógica do sistema em pacotes e as dependências existentes entre eles, sem detalhar atributos ou métodos das classes neles contidas. No RadarTorres, cada pacote corresponde a um *namespace* do projeto `RadarTorres.App`, coincidente com uma pasta do código-fonte, e o diagrama foi obtido diretamente do código da *branch* principal do repositório: cada seta representa ao menos uma diretiva `using RadarTorres.App.*` (ou uma referência `clr-namespace` em XAML) presente nos arquivos do pacote de origem, de modo que o diagrama descreve a estrutura efetivamente implementada, e não apenas a pretendida.

O fluxo principal de dependências segue a organização do padrão MVVM, de cima para baixo: Views → ViewModels → Services → Repositories → Data → Models. O pacote Models ocupa a posição mais estável do sistema – todos os demais dependem dele e ele não depende de nenhum outro –, o que é desejável para as entidades de domínio, e a separação entre as interfaces de Repositories e a implementação em CSV do pacote Data é o que viabiliza a futura migração para um banco relacional sem alterar ViewModels ou Services. A construção do diagrama a partir do código revelou, também, dependências que formam ciclos entre pacotes: o `NavigationService` importa *namespaces* de Views para instanciar telas (Services → Views, fechando o ciclo com Views → ViewModels → Services), e o `DataSeeder`, responsável pela carga inicial de dados, importa Models, Repositories e Services (Data → Repositories/Services, fechando o ciclo com Repositories/Services → Data). Confirmados em `NavigationService.cs` e `DataSeeder.cs` no código atual, esses dois ciclos continuam presentes, mas a figura acima, regenerada ao nível de pacote e não de classe, não os destaca visualmente – ficam registrados apenas neste parágrafo, em vez de perdidos. Eles não impedem o funcionamento da aplicação, pois todos os pacotes pertencem ao mesmo *assembly*, mas aumentam o acoplamento e dificultam testes isolados e futuras separações em projetos distintos.

BANCA_TCC – BOM, MAS PODE MELHORAR: Reconhecimento honesto de um achado desfavorável (ciclos de dependência) que a maioria dos TCCs omitiria – mérito de rigor e transparência.

2.5 Modelo de dados

O protótipo não depende de um servidor de banco de dados externo: a persistência usa **SQLite** (`Microsoft.Data.Sqlite`, arquivo único `radartorres.db` na pasta de dados do usuário), com `PRAGMA foreign_keys = ON` garantindo chaves estrangeiras reais – estágio mais avançado do que o modelo em CSV descrito em versões anteriores deste

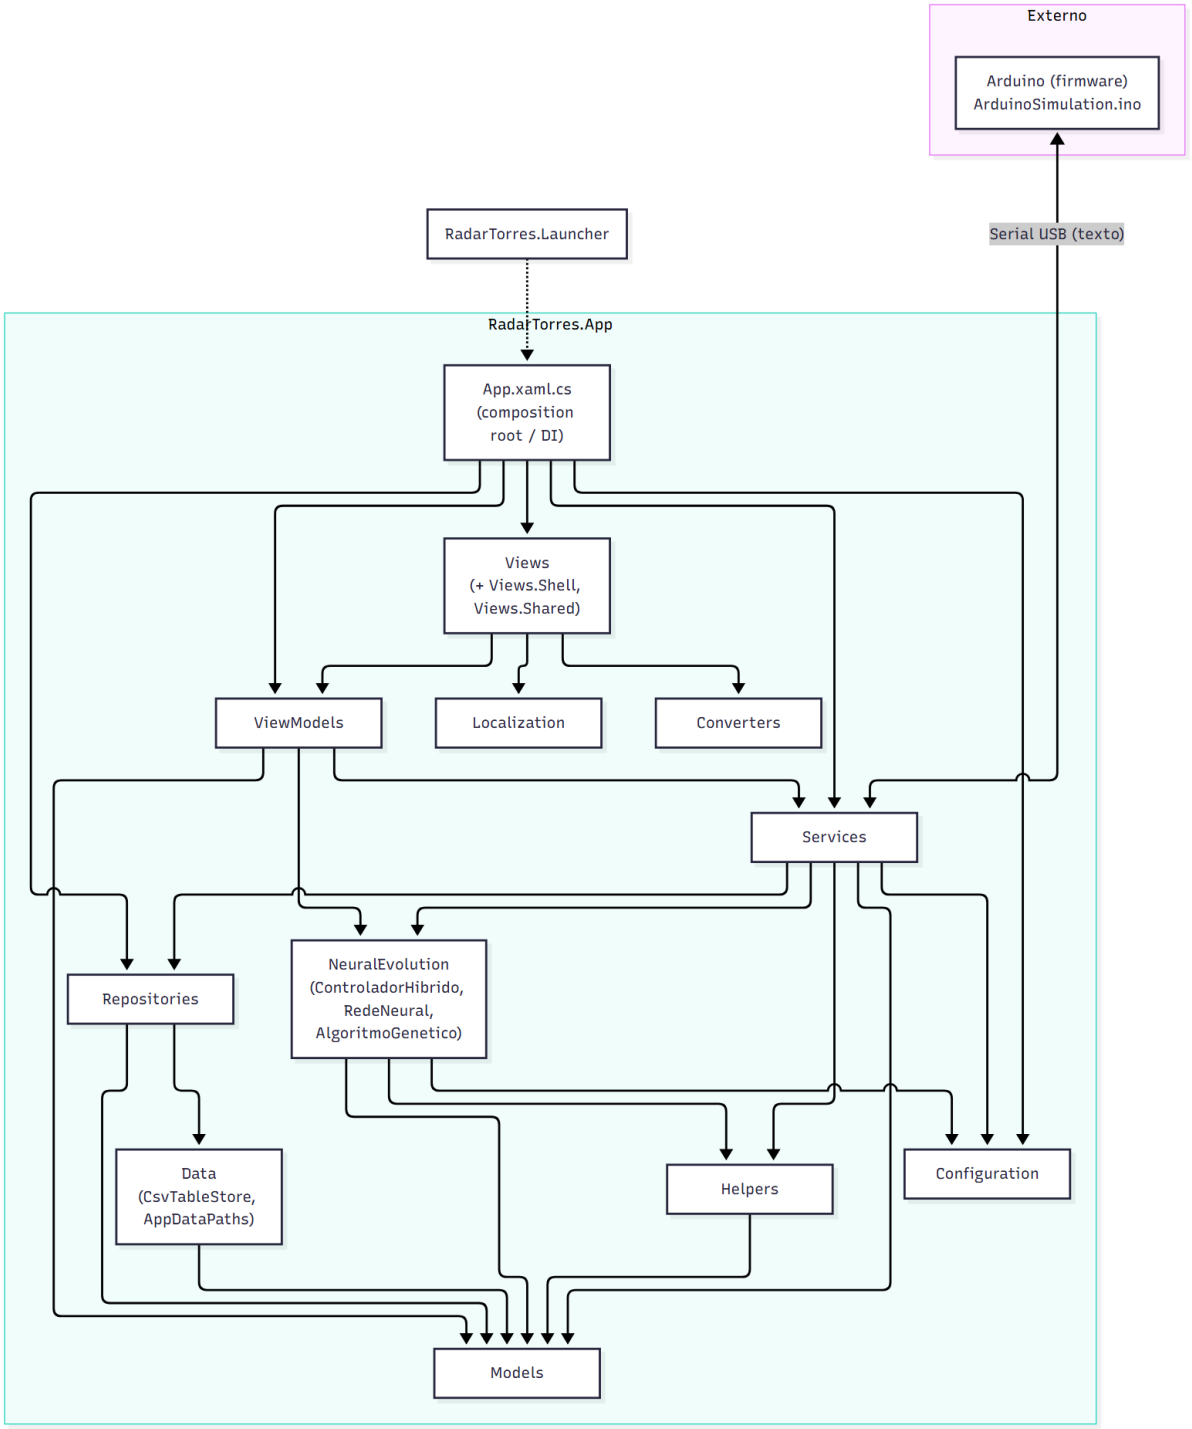


Figure 3: Diagrama de pacotes do RadarTorres. Setas em vermelho indicam dependências que formam ciclos (dos autores).

documento (ver nota histórica adiante). O modelo de dados abaixo foi levantado diretamente do código-fonte já implementado, não de um diagrama projetado antes da codificação. O schema atual tem onze tabelas, listadas na Tabela 3: sete cadastrais/de auditoria, já cobertas pelo levantamento em `conteudo_modelo_banco_dados.tex` (pasta `Banco_de_Dados` dos documentos entregáveis), e quatro exclusivas do treinamento neuroevolutivo, que persistem a evolução do controlador híbrido (Seção 2.3.4) entre execuções.

Table 3: Tabelas do schema SQLite atual (`schema.sql` e os `Sqlite*Repository.cs`).

Tabela	**Finalidade**
`usuarios`	Contas de acesso, perfil (Administrador/Operador/Visualizador) e autenticação
`objetos_detectados`	Histórico de ocorrências de detecção (radar e câmera, por quadrante)
`ocorrencia_estados`	Auditoria das transições de estado de cada ocorrência (só inserção)
`cameras`	Câmera responsável por cada quadrante (Q1–Q4)
`acoes_realizadas`	Auditoria de acionamentos efetivamente executados (só inserção)
`modo_atual_torre`	Auditoria de troca de modo de operação (só inserção)
`preferencias_usuario`	Preferências de interface por usuário (tema, idioma, sidebar)
`classificacoes_alvo`	Classificação de perigo do alvo por velocidade estimada, vinculada a `objetos_detectados` por FK
`historico_treinamento_geracoes`	Fitness (melhor e médio) e contagem de alvos abatidos/escapados a cada geração do algoritmo genético
`marcos_fitness_treinamento`	Agregado de fitness por bloco de gerações, para acompanhar a convergência do treino sem gravar geração a geração
`instantaneos_comportamento_melhor_gene`	Snapshot do comportamento do melhor indivíduo em marcos do treino: fitness, taxa de acerto, taxa de cobertura e o próprio genoma (JSON)

O modelo de dados atual (SQLite, 11 tabelas, chaves estrangeiras reais) é apresentado a seguir em três grupos, por legibilidade: o núcleo de usuários e preferências (Figura 4), o núcleo de detecção, câmeras e auditoria (Figura 5) e as tabelas de treinamento neuroevolutivo, independentes entre si (Figura 6) – diagramas entidade-relacionamento levantados a partir do código-fonte do projeto.

`usuarios` se relaciona 1:1 com `preferencias_usuario` (chave `UsuarioId` → `usuarios.Id`) e 1:N com `modo_atual_torre` (`ID_USER` → `usuarios.Id`) – em ambos os casos por chave estrangeira real de inteiro, não mais por login em texto. `objetos_detectados` se relaciona 1:N com `acoes_realizadas` (quando há alvo as-

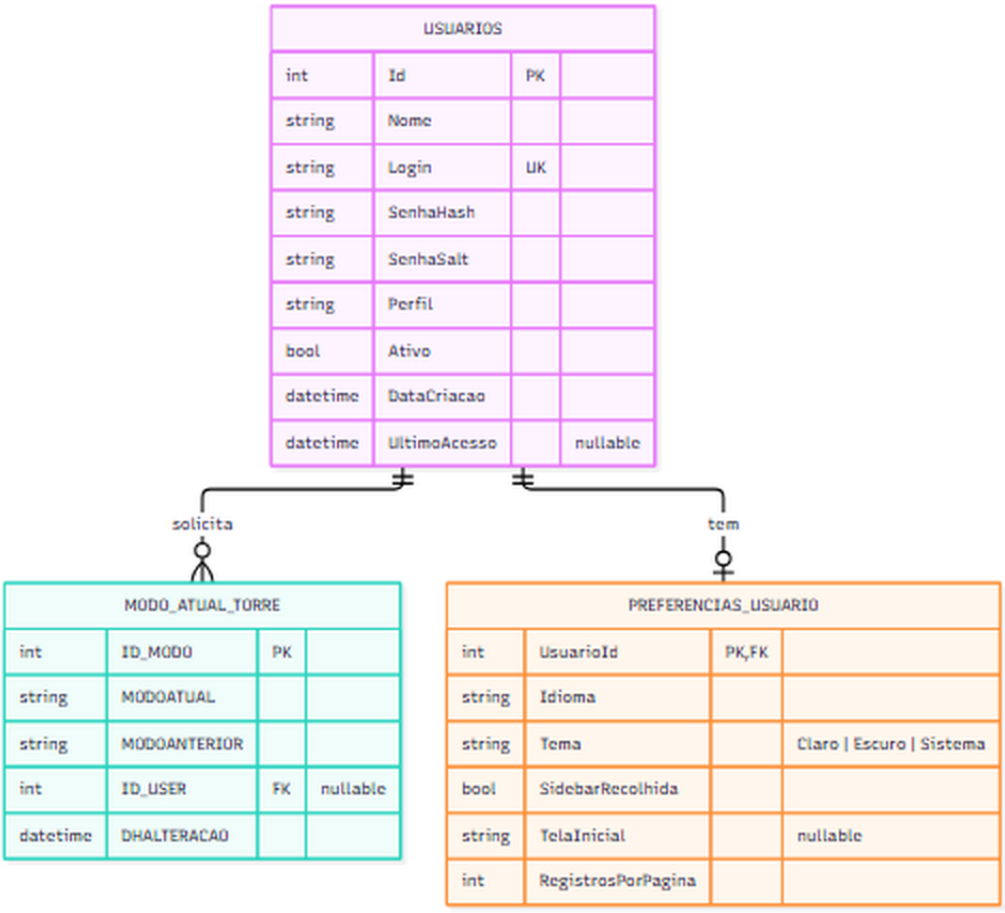


Figure 4: Núcleo de usuários: `usuarios`, `modo_atual_torre` e `preferencias_usuario` (dos autores).

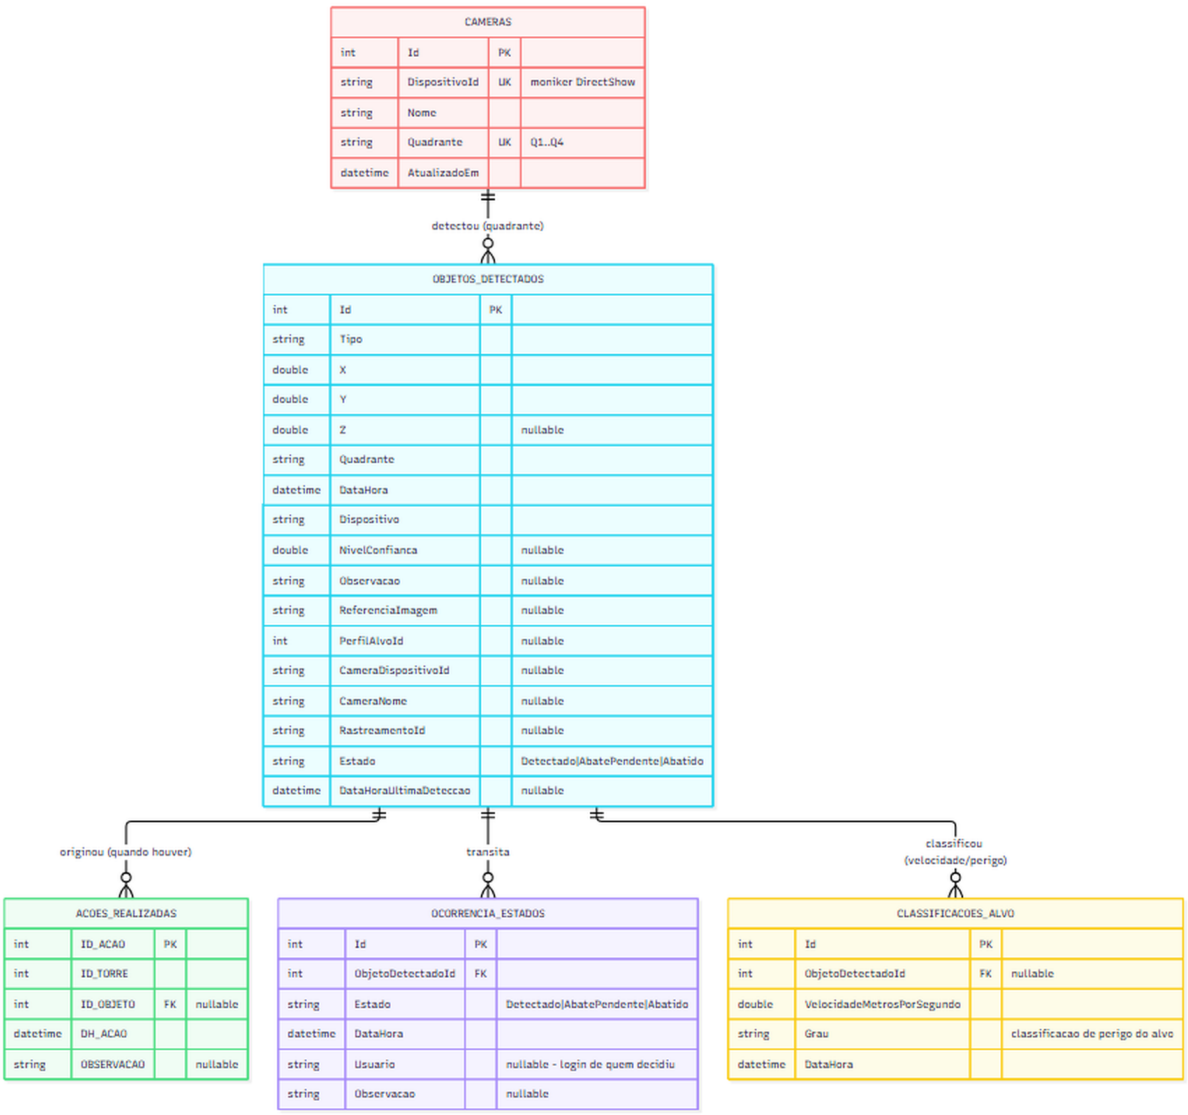


Figure 5: Núcleo de detecção e auditoria: `cameras`, `objetos_detectados`, `acoes_realizadas`, `ocorrencia_estados` e `classificacoes_alvo` (dos autores).

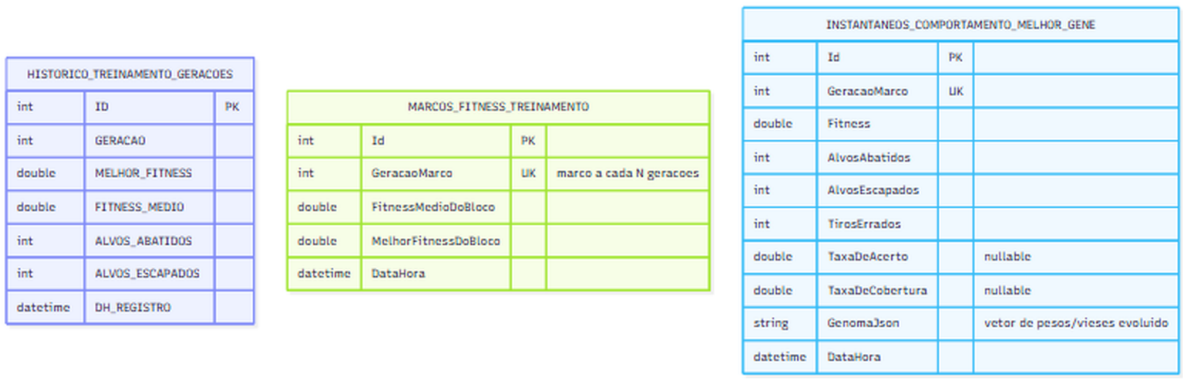


Figure 6: Tabelas de treinamento neuroevolutivo – séries temporais independentes entre si: `historico_treinamento_geracoes`, `marcos_fitness_treinamento` e `instantaneos_comportamento_melhor_gene` (dos autores).

sociado ao acionamento), com `ocorrencia_estados` (histórico de transição de estado) e com `classificacoes_alvo` (`ObjetoDetectadoId` → `objetos_detectados.Id`); `cameras` se relaciona 1:N com `objetos_detectados` pelo quadrante monitorado. As quatro tabelas de treinamento não se relacionam por FK com as demais nem entre si: são séries temporais independentes, cada uma identificada pelo número da geração (`GERACAO/GeracaoMarco`) e pelo instante de registro, cobrindo da granularidade mais fina (`historico_treinamento_geracoes`, uma linha por geração) à mais agregada (`instantaneos_comportamento_melhor_gene`, uma linha por marco, com o genoma completo em JSON).

Como registro histórico do projeto, o modelo original em arquivos CSV tinha seis entidades (sem `ChamadoAjuda`, removida do código) e nenhuma chave estrangeira real – os vínculos entre `Usuario` e `AcaoRealizada/ModoAtualTorre` eram feitos por login em texto. A migração efetivamente realizada seguiu a proposta elaborada a partir desse modelo original para as sete entidades que já existiam, mas foi além dela ao acrescentar as quatro tabelas de treinamento neuroevolutivo, inexistentes na época em que a proposta foi desenhada.

3 Conclusão

Este trabalho descreveu o RadarTorres como um protótipo de rastreamento e seleção automática de alvos construído sobre sensoriamento ultrassônico, visão computacional e um controlador híbrido – heurística determinística que filtra e veta, rede neural pequena que decide dentro do espaço já validado, treinada por algoritmo genético. A contribuição mais original deste trabalho é empírica: a identificação e correção, documentada por commit, de uma falha em que a certeza de identificação do alvo era sorteada uma única vez e nunca atualizada, mantendo cerca de 70% dos alvos simulados permanentemente abaixo do limiar de disparo e mascarando a estagnação evolutiva sob a aparência de um treino funcional. A Tabela 1 (Seção anterior) quantifica o efeito dessa correção: o fitness médio da população, estagnado em torno de 9 ao longo de 25.500 gerações antes da correção, passou a acompanhar de perto o fitness do melhor indivíduo depois dela, e a cobertura de alvos disparáveis foi de uma fração minoritária para 100% nas amostras pós-correção.

As limitações do protótipo, discutidas ao longo do texto, concentram-se em três pontos: (i) o hardware físico ainda não foi montado – toda validação é feita em simulação, com modelos (certeza de identificação, probabilidade de erro de disparo) assumidos e não calibrados com dados de campo; (ii) a comunicação entre a visão computacional e o Arduino para guiar o apontamento de pan/tilt foi projetada mas não implementada, permanecendo como integração pendente; e (iii) a propriedade de projeto que limita o controlador híbrido, no pior caso, ao comportamento puramente heurístico (nunca a uma decisão arbitrária da rede) ainda não foi submetida a validação em hardware físico real.

Os trabalhos futuros identificados neste artigo são, portanto: montagem e validação do hardware físico das cinco torres; implementação do comando de apontamento no protocolo serial e da fusão entre a posição estimada pela visão e a distância ultrassônica; calibração dos modelos de certeza e de erro de disparo com dados de campo, substituindo as premissas simuladas; extensão da seleção de torre para a abordagem multiameaça da literatura

de TEWA, hoje deixada de lado em favor da abordagem por proximidade; e, caso a capacidade da rede se mostre o fator limitante do controlador em vez dos hiperparâmetros da busca evolutiva, avaliação de uma arquitetura maior à luz dos resultados de Such et al. (2017).

Parecer final da banca (Banca_TCC, revisão automatizada desta versão)

Nota geral

≈ 6,33/10 – ver tabela de critérios e justificativas completas em `Parecer_Banca_TCC.pdf`, Seção B.

Coerência geral

Trabalho tecnicamente competente, com uma contribuição empírica real e bem documentada (o bug de certeza estática, Tabela 1) e uma honestidade metodológica consistente sobre a ausência de hardware físico. O problema central que permanece é a mistura, sem sinalização ao leitor, de afirmações com proveniência muito diferente: parte rastreável ao código linha a linha (o controlador neuroevolutivo, Seção 2.3.5), parte admitidamente não confirmada em código nem em documentação (projeto elétrico/estrutural, Seção 2.3.2, e parte do módulo de visão, Seção 2.3.3) – o que contradiz diretamente a alegação de rastreabilidade total feita na Seção 2.2. Soma-se a leitura interpretativa incompleta da Tabela 2 (Seção 2.3.6), que não discute a causa determinística mais provável da convergência exata observada.

Veredito: APROVADO COM RESSALVAS – os itens marcados **BANCA_TCC – PROBLEMA CRÍTICO/ALTO** nesta revisão precisam ser resolvidos antes da entrega final/defesa; os marcados **AJUSTAR** são recomendados, mas não impediriam a defesa.

Plano de correção priorizado

Prior.	Ação	Motivo
1 (máx.)	Discutir no texto a causa determinística provável da convergência exata na Tabela 2 (Seção 2.3.6)	Afeta diretamente a validade da conclusão mais recente e mais citada do artigo
2 (máx.)	Reconciliar a Seção 2.3.2 (elétrico/estrutural) e parte da 2.3.3 (visão) com a documentação técnica real, ou sinalizar a incerteza no próprio PDF	Contradição direta com a alegação metodológica central do artigo (Seção 2.2)
3 (alta)	Preencher a citação pendente sobre classificação por cor/forma/tamanho (comentário "PREENCHER" na Seção 2.1)	Lacuna teórica central já identificada pelo próprio autor
4 (alta)	Versionar o genoma embutido (`genoma-controlador.json`) junto com a versão final do artigo	O artefato citado no texto já diverge do estado atual do repositório
5 (média)	Completar o `.bib` com DOI/veículo/páginas, especialmente para as referências centrais (Such 2017, Huang & Ontañón 2020, Alshiekh 2017)	Abaixo do padrão mínimo de rastreabilidade bibliográfica

Prior.	Ação	Motivo
6 (média)	Marcar explicitamente, na Tabela 1, qual célula é estimativa derivada vs. medição direta	Evita confundir leitor sobre a natureza do número
7 (baixa)	Preencher o placeholder "Mestre em xxx pela xxx" no rodapé do orientador	Pendência de formatação antes de qualquer submissão formal
8 (baixa)	Resolver *overfull/underfull hboxes* remanescentes e remover macros de revisão (\`revmudar` etc.) não utilizadas	Polimento final de tipografia

O parecer completo (seções A a J, nota ponderada por critério, auditoria de referências e de figuras/tabelas, e as perguntas que a banca provavelmente fará na defesa) está em `Parecer_Banca_TCC.pdf`, gerado na mesma análise que originou estas marcações.

Referências

ALSHIEKH, M. et al. *Safe Reinforcement Learning via Shielding*. 2017.

BAEK, I. et al. *CurbScan: Curb Detection and Tracking Using Multi-Sensor Fusion*. 2020.

COLAS, C.; SIGAUD, O.; OUDEYER, P.-Y. *How Many Random Seeds? Statistical Power Analysis in Deep Reinforcement Learning Experiments*. 2018.

DERRAC, J. et al. A practical tutorial on the use of nonparametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms. *Swarm and Evolutionary Computation*, v. 1, n. 1, p. 3–18, 2011.

GONZALEZ, R. C.; WOODS, R. E. *Digital Image Processing*. 4. ed. New York: Pearson, 2018.

HENDERSON, P. et al. Deep reinforcement learning that matters. In: *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*. [S.l.: s.n.], 2018. p. 3207–3214.

HOOKER, J. N. Testing heuristics: We have it all wrong. *Journal of Heuristics*, v. 1, n. 1, p. 33–42, 1995.

HU, M.-K. Visual pattern recognition by moment invariants. *IRE Transactions on Information Theory*, v. 8, n. 2, p. 179–187, 1962.

HUANG, S.; ONTAÑÓN, S. *A Closer Look at Invalid Action Masking in Policy Gradient Algorithms*. 2020.

MAJONI, L. et al. Camera and ultrasonic sensor fusion for electronic travel aid: design and performance analysis. *MATEC Web of Conferences*, v. 417, p. 10005, 2025.

NAEEM, H. et al. *A Novel Two-Stage Dynamic Decision Support based Optimal Threat Evaluation and Defensive Resource Scheduling Algorithm for Multi Air-borne threats*. 2009.

NAEEM, H. et al. *A Novel Two-Staged Decision Support based Threat Evaluation and Weapon Assignment Algorithm, Asset-based Dynamic Weapon Scheduling using Artificial Intelligence Techniques*. 2009.

RISI, S.; TOGELIUS, J. Neuroevolution in games: state of the art and open challenges. *IEEE Transactions on Computational Intelligence and AI in Games*, v. 9, n. 1, p. 25–41, 2017.

SALIMANS, T. et al. *Evolution Strategies as a Scalable Alternative to Reinforcement Learning*. 2017.

SUCH, F. P. et al. *Deep Neuroevolution: Genetic Algorithms Are a Competitive Alternative for Training Deep Neural Networks for Reinforcement Learning*. 2017.

SWAIN, M. J.; BALLARD, D. H. Color indexing. *International Journal of Computer Vision*, v. 7, n. 1, p. 11–32, 1991.

Ultralytics. *YOLO26: Model Documentation*. 2025. ⟨https://docs.ultralytics.com/models/yolo26/⟩. Acesso em: 28 out. 2026.